

UNIVERSIDADE DE SÃO PAULO
INSTITUTO DE MATEMÁTICA E ESTATÍSTICA
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

**Sobre a conjectura do número de queima
de um grafo**

Lucas Sepeda Lima

MONOGRAFIA FINAL

MAC 499 — TRABALHO DE
FORMATURA SUPERVISIONADO

Supervisor: Prof. Dr. Fábio H. Botler

São Paulo
2025

*O conteúdo deste trabalho é publicado sob a licença CC BY 4.0
(Creative Commons Attribution 4.0 International License)*

Ao Blues, pela companhia silenciosa.

Resumo

Lucas Sepeda Lima. **Sobre a conjectura do número de queima de um grafo**. Monografia (Bacharelado). Instituto de Matemática e Estatística, Universidade de São Paulo, São Paulo, 2025.

O processo de queima de grafos foi introduzido como um modelo determinístico para a propagação de informação em redes, dando origem ao parâmetro conhecido como número de queima. Uma conjectura central associada a esse processo afirma que todo grafo conexo com n vértices possui número de queima no máximo $\lceil \sqrt{n} \rceil$. O objetivo deste trabalho é estudar de forma detalhada e sistemática a prova recente de Norin e Turcotte de que essa conjectura vale assintoticamente, isto é, que $b(G) \leq (1 + o(1)) \sqrt{n}$. Em vez de focar apenas no resultado final, o trabalho dedica-se a explicar cuidadosamente todas as etapas do argumento, reconstruindo a cadeia lógica completa que leva do modelo discreto original ao limitante assintótico. A metodologia adotada baseia-se na reinterpretação da queima como um problema de cobertura por bolas, na passagem para o cenário contínuo de árvores métricas e na introdução de ferramentas probabilísticas centrais, como coberturas aleatórias, a medida de expectativa e o controle do momento associado a essas distribuições. Ao longo do texto, investigam-se com atenção as técnicas probabilísticas empregadas, destacando seu papel na obtenção de distribuições quase uniformes de raios e na globalização dos resultados locais. Por fim, analisa-se o retorno dessas construções ao contexto discreto, completando a demonstração do comportamento assintótico da conjectura. O trabalho tem caráter expositivo e visa tornar o método de Norin e Turcotte acessível e reutilizável em problemas análogos de cobertura em grafos.

Palavras-chave: Número de queima. Queima de grafos. Coberturas em árvores. Métodos probabilísticos. Teoria dos grafos.

Abstract

Lucas Sepeda Lima. **About the burning number conjecture.** Capstone Project Report (Bachelor). Institute of Mathematics and Statistics, University of São Paulo, São Paulo, 2025.

The graph burning process was introduced as a deterministic model for the spread of information in networks, giving rise to the parameter known as the burning number. A central conjecture associated with this process states that every connected graph on n vertices has burning number at most $\lceil \sqrt{n} \rceil$. The aim of this work is to study in detail the recent proof by Norin and Turcotte that this conjecture holds asymptotically, namely that $b(G) \leq (1 + o(1))\sqrt{n}$. Rather than focusing solely on the final result, the text is devoted to a careful explanation of each step of the argument, reconstructing the full logical chain that leads from the original discrete burning model to the asymptotic bound. The methodology follows the original approach closely, reinterpreting burning as a covering problem, passing to the continuous setting of metric trees, and introducing key probabilistic tools such as random coverings, expectation measures, and moment control. Special attention is given to the probabilistic techniques employed and to their role in producing near-uniform distributions of radii and in globalizing local constructions. Finally, the transfer of these results back to the discrete graph setting is analyzed, completing the asymptotic argument. This work is expository in nature and aims to make the method of Norin and Turcotte transparent and accessible for future applications to related covering problems in graph theory.

Keywords: Burning number. Graph burning. Tree coverings. Probabilistic methods. Graph theory.

Sumário

1	A Conjectura do Número de Queima	1
1.1	Propagação de informação e modelagem em grafos	1
1.2	O processo de queima	1
1.3	A Conjectura do Número de Queima	2
2	Árvores métricas e Reduções estruturais	5
2.1	Árvores métricas: definições e propriedades básicas	5
2.2	Compacidade e Lemas Estruturais	7
3	Coberturas em árvores métricas: frugalidade e flexibilidade	11
3.1	Coberturas de uma única bola	12
3.2	Um critério de soma de raios	13
3.3	Coberturas por duas bolas em árvores ℓ -minimais	14
3.4	Síntese e conexão com o Capítulo 4	17
4	Coberturas aleatórias, medida de expectativa e momento	19
4.1	Coberturas aleatórias e medida de expectativa	19
4.2	O momento da medida de expectativa	22
4.3	Medidas (r, δ) -controladas	24
4.4	Lemas de colagem para medidas (r, δ) -controladas	26
4.4.1	Lema de colagem I: operações básicas em $C(T, l)$	26
4.4.2	Lema de colagem II: controle em uma árvore $2(1 - \delta)r$ -minimal	31
4.4.3	Lema de colagem III: controle global em qualquer árvore métrica	32
5	O Teorema Fundamental em Árvores Métricas	35
5.1	Enunciado e interpretação do teorema	35
5.2	Estratégia de prova	36
5.3	Prova detalhada do Teorema 5.1.1	37

6	Concentração, Arredondamento e Passagem ao Caso Discreto	45
6.1	Desigualdades de concentração	45
6.1.1	Desigualdade de Markov	45
6.1.2	Desigualdade de Hoeffding	46
6.2	Enunciado e interpretação do Teorema 5.3	46
6.3	Demonstração do Teorema 5.3	47
7	Retorno ao Discreto e Resultado Assintótico	55
7.1	Enunciado do resultado principal	55
7.2	Transferência métrica–discreta	56
7.3	Demonstração do Teorema 1.2	57
7.4	Comentários finais	59
8	Conclusão	61
 Apêndices		
 Anexos		
 Referências		65

Capítulo 1

A Conjectura do Número de Queima

1.1 Propagação de informação e modelagem em grafos

A difusão de “contágios”, sejam vírus biológicos, pacotes de dados ou memes, é um fenômeno recorrente em Ciência da Computação e em ciência de redes. Redes de computadores, por exemplo, devem disseminar atualizações com baixa latência; já redes sociais on-line difundem tendências capazes de alcançar milhões de usuários em poucos minutos. Esse tipo de dinâmica motiva processos discretos sobre grafos em que a influência se propaga localmente ao longo das arestas, como o *bootstrap percolation* e o problema do *Firefighter* (BALOGH *et al.*, 2012, FINBOW e MACGILLIVRAY, 2009).

Nesse contexto, Bonato, Janssen e Roshanbin introduziram o *processo de queima* (*graph burning*) como um modelo determinístico e discreto de difusão em grafos (BONATO *et al.*, 2016). O parâmetro associado, chamado *número de queima*, mede o tempo mínimo necessário para que a influência (o “fogo”) alcance todos os vértices, supondo que em cada rodada é permitido iniciar um novo foco em um vértice ainda não atingido.

1.2 O processo de queima

Seja $G = (V, E)$ um grafo finito e conexo. No instante inicial, todos os vértices estão *não queimados*. Para cada passo discreto $t \geq 1$, executam-se as duas ações a seguir: (i) escolhe-se **um** vértice ainda não queimado e inicia-se um novo foco de fogo nesse vértice; (ii) em seguida, todo vértice que possui um vizinho queimado no passo $t - 1$ torna-se queimado no passo t . O processo termina quando todos os vértices estão queimados.

As escolhas feitas em (i) determinam uma sequência $(x_1, \dots, x_k)$ de vértices, chamada *sequência de ignição*. Dizemos que $(x_1, \dots, x_k)$ *queima* G em k passos se, ao final do passo k , todos os vértices de G estão queimados. O *número de queima* $b(G)$ é o menor inteiro k para o qual existe uma sequência de ignição que queime G em k passos (BONATO *et al.*, 2016).

A perspectiva que guiará os capítulos seguintes é uma reformulação métrica do pro-

cesso, não apenas por elegância formal, mas porque ela torna explícita a natureza de *problema de cobertura* embutida no modelo. O ponto é que, quando iniciamos um foco em x_i no passo i , o fogo proveniente dessa fonte pode atingir, até o final do passo k , exatamente os vértices a distância no máximo $k - i$ de x_i . Assim, queimar um grafo em k passos equivale a cobri-lo por bolas cujos raios são prescritos e decrescem com o tempo.

Seja $d_G(u, v)$ a distância em G , isto é, o número de arestas de um caminho mínimo ligando u a v . Para $v \in V$ e $r \geq 0$, definimos a *bola fechada* de raio r centrada em v por

$$N_r[v] = \{u \in V : d_G(u, v) \leq r\},$$

escrevendo $N[v]$ quando $r = 1$. Dizemos que uma família $\{N_{r_i}[x_i]\}_{i=1}^m$ cobre G se $\bigcup_{i=1}^m N_{r_i}[x_i] = V$.

Suponha que $(x_1, \dots, x_k)$ queime G em k passos. Então todo vértice $v \in V$ é atingido por algum foco x_i a distância no máximo $k - i$, o que implica a cobertura

$$N_{k-1}[x_1] \cup N_{k-2}[x_2] \cup \dots \cup N_0[x_k] = V.$$

Além disso, a própria definição de sequência de ignição impõe uma condição de separação: para $i < j$, deve valer

$$d_G(x_i, x_j) \geq j - i,$$

pois caso $d_G(x_i, x_j) < j - i$, o vértice x_j já teria sido alcançado pelo fogo iniciado em x_i antes do passo j , e não poderia ser escolhido como novo foco (Bonato et al., 2016).

A recíproca também é verdadeira: se existem vértices $x_1, \dots, x_k$ que satisfazem simultaneamente a igualdade de cobertura acima e a condição de separação $d_G(x_i, x_j) \geq j - i$ para todo $i < j$, então a regra de ignição “queime x_i no passo i ” é bem definida e queima G em k passos. Concluimos, portanto, a caracterização métrica:

$$b(G) = \min \left\{ k \in \mathbb{N} : \exists x_1, \dots, x_k \in V \text{ s.t. } \bigcup_{i=1}^k N_{k-i}[x_i] = V \text{ e } d_G(x_i, x_j) \geq j - i \text{ (} i < j \text{)} \right\}.$$

Em particular, ao ignorar a condição de separação, uma mera cobertura por bolas de raios $k - 1, k - 2, \dots, 0$ ainda fornece o limitante superior $b(G) \leq k$ (BONATO et al., 2016).

1.3 A Conjectura do Número de Queima

Bonato et al. mostraram que os caminhos atingem a cota $b(P_n) = \lceil \sqrt{n} \rceil$ e propuseram a *Conjectura do Número de Queima* (BONATO et al., 2016).

Conjectura 1.3.1. *Se G é conexo com n vértices, então $b(G) \leq \lceil \sqrt{n} \rceil$.*

A conjectura sugere que caminhos são, em certo sentido, os grafos “mais difíceis” de queimar. Em geral, determinar $b(G)$ é computacionalmente difícil: o problema de decisão associado é NP-completo mesmo em subclasses de árvores (BESSY et al., 2017). Por isso, a literatura se concentra em limitantes superiores gerais para $b(G)$ em função de n .

O primeiro limitante universal provado por Bonato et al. foi $b(G) \leq 2\lceil \sqrt{n} \rceil - 1$ (BONATO *et al.*, 2016). Trabalhos subsequentes reduziram a constante multiplicativa na frente de $\sqrt{n}$, passando por $b(G) \leq \sqrt{\frac{3}{2}}n + O(1)$ (LAND e LU, 2016) e chegando ao melhor limitante anterior ao resultado assintótico, $b(G) \leq \sqrt{\frac{4}{3}}n + 1$ (BASTIDE *et al.*, 2021).

Além de avanços em limitantes universais, também houve progresso ao confirmar a conjectura em classes estruturadas de grafos, em especial de árvores. Um exemplo recente é o trabalho de Murakami, que prova a Conjectura do Número de Queima para as chamadas *árvores homeomorficamente irredutíveis* (ou *HITs*), isto é, árvores sem vértices de grau 2 (MURAKAMI, 2024). Em outras palavras, se T é uma árvore com n vértices e nenhum vértice de grau 2, então vale $b(T) \leq \lceil \sqrt{n} \rceil$. Esse tipo de resultado reforça a intuição de que a presença de longos “trechos lineares” (cadeias de vértices de grau 2) está relacionada às instâncias mais difíceis do problema, e complementa o panorama de limitantes gerais ao atacar diretamente casos extremos dentro da classe das árvores.

O avanço recente de Norin e Turcotte estabelece que a conjectura vale *assintoticamente*, isto é, $b(G) \leq (1 + o(1))\sqrt{n}$ (NORIN e TURCOTTE, 2024). Embora essa afirmação tenha uma forma final concisa, a demonstração no artigo é longa e tecnicamente sofisticada: ela combina uma redução do problema discreto a árvores, uma passagem para árvores métricas (contínuas) e a construção de coberturas aleatórias quase-uniformes controladas por ferramentas probabilísticas e analíticas. O objetivo central deste trabalho é justamente tornar esse argumento transparente. Em vez de apenas reproduzir o encadeamento de resultados, buscamos destrinchar as ideias estruturais que sustentam a prova, explicitar as escolhas conceituais que motivam cada definição e detalhar as passagens que, na escrita original, aparecem condensadas. Em particular, adotamos uma exposição pedagógica das noções de cobertura fracionária em árvores métricas, de medidas de expectativa e de controle quase-uniforme, de modo que o mecanismo do método se torne intuitivo para o leitor.

Assim, o resultado de Norin e Turcotte é ao mesmo tempo o foco principal desta tese e o ponto de partida para os capítulos seguintes, nos quais desenvolvemos gradualmente o aparato probabilístico e contínuo necessário para compreender a prova em detalhe, culminando na versão métrica-fracionária do teorema e, posteriormente, no retorno ao cenário discreto.

Capítulo 2

Árvores métricas e Reduções estruturais

A estratégia de prova presente em [NORIN e TURCOTTE, 2024](#) para a solução assintótica da conjectura do número de queima baseia-se em uma passagem sistemática de estruturas discretas para estruturas contínuas. Em vez de trabalhar diretamente com grafos, reduzimos o problema a árvores e, em seguida, substituímos cada aresta por um intervalo fechado de comprimento real positivo, obtendo assim uma árvore como espaço métrico compacto. Essa reformulação permite utilizar argumentos de compacidade, decomposições contínuas e, sobretudo, coberturas por bolas de raios reais que serão posteriormente randomizadas.

Recordemos que, para todo grafo conexo G , existe uma árvore geradora T tal que as distâncias em G são menores ou iguais às distâncias em T , de modo que toda sequência de ignição que queima T também queima G . Em particular, $b(G) \leq b(T)$ ([BONATO et al., 2016](#)). Assim, para fins assintóticos, é suficiente estabelecer os resultados-alvo no caso de árvores, e a passagem para árvores métricas prepara o terreno para os argumentos probabilísticos centrais.

Neste capítulo, formalizamos as árvores métricas e enunciamos os principais lemas estruturais presentes em [NORIN e TURCOTTE, 2024](#) (Lema 2.2.1 a Lema 2.2.6) que governam sua geometria: como o diâmetro se controla a partir de um núcleo central, como se comparam profundidades de subestruturas e, finalmente, como decompor uma árvore em peças de tamanho comparável. Esses resultados serão usados de forma recorrente nos capítulos seguintes para reduzir construções globais a situações locais controladas.

2.1 Árvores métricas: definições e propriedades básicas

Seja T_0 uma árvore finita. Uma *árvore métrica* T é obtida a partir de T_0 substituindo cada aresta e por um intervalo fechado de comprimento $\ell(e) > 0$, identificando as extremidades do intervalo com os vértices incidentes a e em T_0 . O conjunto subjacente T é, portanto, uma união finita de intervalos fechados colados em suas extremidades, o que implica

que T é compacto.

A métrica $d_T(u, v)$ entre pontos $u, v \in T$ é definida como o comprimento do caminho único que os conecta. Denotamos por $|T|$ o comprimento total de T , isto é, a soma dos comprimentos dos intervalos correspondentes às arestas de T_0 .

Um ponto $v \in T$ é uma *folha* se $T \setminus \{v\}$ é conexo. Um ponto é *ponto de bifurcação* se $T \setminus \{v\}$ possui pelo menos três componentes conexas. Denotamos por $L(T)$ o conjunto de folhas e por $Br(T)$ o conjunto de pontos de bifurcação. As componentes de $T \setminus (L(T) \cup Br(T))$ são homeomorfas a intervalos abertos, e os *segmentos* de T são os fechos dessas componentes. Em particular, todo ponto de $T \setminus Br(T)$ pertence a um único segmento, e as extremidades de todo segmento pertencem a $L(T) \cup Br(T)$.

O diâmetro de T , bem definido por compacidade, é

$$\text{diam}(T) = \max_{u, v \in T} d_T(u, v).$$

Subárvores, decomposições e galhos

Diremos que $T' \subseteq T$ é uma *subárvore* se é um subconjunto conexo (com a métrica induzida). Por exemplo, para quaisquer $u, v \in T$, o caminho $T[u, v]$ é uma subárvore.

Uma coleção $\mathcal{T} = \{T_1, \dots, T_k\}$ de subárvores de T é uma *decomposição* de T se

$$T = \bigcup_{i \in [k]} T_i \quad \text{e} \quad |T| = \sum_{i=1}^k |T_i|.$$

A igualdade de comprimentos equivale a exigir que as subárvores sejam internamente disjuntas: elas podem se tocar em pontos, mas não compartilham um subconjunto de comprimento positivo.

Para uma subárvore $T' \subseteq T$, denotamos por $\overline{T'}$ o fecho de $T \setminus T'$. Denotamos por $\text{comp}(\overline{T'})$ o conjunto de componentes conexas de $\overline{T'}$. Cada componente $J \in \text{comp}(\overline{T'})$ é uma subárvore de T e encontra T' em exatamente um ponto.

Uma subárvore $B \subset T$ é chamada *galho* se $\overline{B}$ é conexo e não-vazio. Nesse caso, existe um único ponto

$$a = \text{anc}(B) \in B \cap \overline{B},$$

chamado *âncora* de B . A *profundidade* de B é definida por

$$\text{dp}(B) = \max_{v \in B} d_T(a, v) = \max_{v \in B} d_T(\text{anc}(B), v).$$

Intuitivamente, $\text{dp}(B)$ mede quão longe o galho se estende a partir do ponto em que ele se conecta ao restante da árvore.

2.2 Compacidade e Lemas Estruturais

Um dos benefícios do ponto de vista métrico é que o conjunto de subárvores de T pode ser munido da distância de Hausdorff, tornando-se um espaço compacto. Seja $S(T)$ o conjunto de subárvores de T e, para $T_1, T_2 \in S(T)$, definimos

$$d_{S(T)}(T_1, T_2) = \max \left\{ \max_{u \in T_1} d_T(u, T_2), \max_{u \in T_2} d_T(u, T_1) \right\}.$$

A compacidade de $S(T)$ permite escolher subárvores “ótimas” por argumentos de maximização e minimização, os quais aparecem como um ingrediente técnico na demonstração de resultados estruturais em [NORIN e TURCOTTE, 2024](#).

A seguir, enunciaremos os Lemas 2.2.1–2.2.6 de [NORIN e TURCOTTE, 2024](#). Eles serão usados como ferramentas estruturais, e portanto não os demonstraremos aqui; em cada caso, incluímos apenas uma breve intuição e indicação de uso.

Lema 2.2.1 (Limitante do diâmetro). *Seja $z \geq 0$ e seja $T' \subseteq T$ uma subárvore de uma árvore métrica T tal que $\text{dp}(J) \leq z$ para toda componente $J \in \text{comp}(\overline{T'})$. Então*

$$\text{diam}(T) \leq \text{diam}(T') + 2z.$$

Este lema formaliza a ideia de que, se removemos um núcleo T' e todos os pedaços restantes têm profundidade no máximo z , então quaisquer dois pontos de T podem ser conectados passando por T' , pagando no máximo z em cada extremidade. Mais adiante, ele permitirá transferir construções feitas em um núcleo controlado para garantias globais sobre o diâmetro e sobre raios de coberturas.

Lema 2.2.2 (Hierarquia de profundidades). *Sejam B', B'' galhos de uma árvore métrica T tais que $B'' \subseteq B'$. Então*

$$\text{dp}(B') \geq \text{dp}(B'') + d_T(\text{anc}(B'), \text{anc}(B'')).$$

A intuição é que, para alcançar um ponto profundo dentro de B'' partindo da âncora de B' , é necessário primeiro percorrer a distância entre as âncoras e, em seguida, avançar até o ponto mais distante de B'' . Esse tipo de desigualdade será usado para comparar escalas ao longo de decomposições aninhadas.

Lema 2.2.3 (Existência de um núcleo com até três folhas). *Se T é uma árvore métrica, então existem $z \geq 0$ e uma subárvore $T' \subseteq T$ tais que:*

- (i) T' tem no máximo três folhas;
- (ii) $\text{dp}(J) \leq z$ para toda componente $J \in \text{comp}(\overline{T'})$;
- (iii) para todo $v \in L(T')$ existe $J \in \text{comp}(\overline{T'})$ tal que $\text{anc}(J) = v$ e $\text{dp}(J) = z$;
- (iv) $|T| \geq |T'| + 4z$.

Este é o principal lema de redução estrutural do capítulo. Ele afirma que toda árvore métrica contém um núcleo extremamente simples—com formato de caminho ou tripé,

pois tem no máximo três folhas—tal que o restante da árvore se organiza em galhos de profundidade limitada por z . O item (iii) garante que o parâmetro z não é apenas uma cota superior: ele é atingido a partir de cada folha do núcleo. Já o item (iv) assegura que a parte fora do núcleo é substancial em comprimento, um aspecto importante quando o argumento posterior precisa extrair progresso quantitativo em passos indutivos.

Peças quase homogêneas: árvores ℓ -minimais

Os próximos lemas formalizam uma decomposição em escala: a árvore pode ser particionada em peças cujos comprimentos são comparáveis. Fixe $\ell > 0$. Dizemos que uma árvore métrica S é ℓ -*minimal* se $|S| \geq \ell$ e existe uma decomposição $\{S', S''\}$ de S tal que $|S'| \leq \ell$ e $|S''| \leq \ell$. Em particular, uma árvore ℓ -minimal sempre satisfaz $|S| \leq 2\ell$.

Lema 2.2.4 (Extração de um bloco ℓ -minimal). *Se $\ell > 0$ e T é uma árvore métrica tal que $|T| \geq \ell$, então existe uma decomposição $\{T_0, T_1\}$ de T tal que T_1 é ℓ -minimal.*

A leitura conceitual é que, em qualquer árvore suficientemente longa, é possível isolar uma peça T_1 que seja “quase indivisível” na escala ℓ : ela tem tamanho pelo menos ℓ , mas pode ser cortada em duas partes, ambas com tamanho no máximo ℓ . Esse tipo de bloco será uma unidade natural para colagens e para argumentos por partes.

Lema 2.2.5 (Decomposição em blocos ℓ -minimais). *Para toda árvore métrica T e todo $\ell > 0$ existe uma decomposição $\{T_0, T_1, \dots, T_k\}$ de T tal que $|T_0| \leq \ell$ e $T_1, \dots, T_k$ são ℓ -minimais.*

Este lema afirma que a árvore inteira pode ser escrita como união disjunta (em comprimento) de blocos ℓ -minimais, exceto por um possível resto T_0 de tamanho no máximo ℓ . Do ponto de vista metodológico, ele permite tratar a geometria de T como composta por várias peças “quase homogêneas” na mesma escala.

Lema 2.2.6 (Decomposição em peças de tamanho comparável). *Para toda árvore métrica T e todo $0 < \ell \leq |T|$ existe uma decomposição $\mathcal{T}$ de T tal que*

$$\ell \leq |S| \leq 3\ell \quad \text{para todo } S \in \mathcal{T}.$$

Este é o formato mais conveniente da decomposição em escala: ele garante que todas as peças possuem tamanho dentro de uma janela fixa $[\ell, 3\ell]$. Essa uniformidade aproximada será essencial nos capítulos probabilísticos, pois permite aplicar construções locais de forma aproximadamente homogênea, além de facilitar o uso de desigualdades de concentração quando as peças são tratadas de maneira independente.

Síntese e conexão com o Capítulo 3

Os Lemas 2.2.1–2.2.3 mostram como reduzir a geometria global de uma árvore métrica a um núcleo muito simples, com no máximo três folhas, preservando controle quantitativo sobre o resto via profundidade e, conseqüentemente, sobre o diâmetro. Já os Lemas 2.2.4–2.2.6 fornecem decomposições em escala que particionam T em peças de comprimento comparável, adequadas para argumentos de colagem e para construções por partes.

No Capítulo 3, essas ferramentas serão combinadas com o ponto de vista de cobertura por bolas para estudar quais multiconjuntos de raios podem cobrir uma árvore métrica. Em particular, a redução a núcleos com poucas folhas permitirá concentrar o esforço técnico em casos-base altamente estruturados, enquanto as decomposições em escala prepararão o terreno para passos indutivos que mais adiante serão aleatorizados na passagem para o Capítulo 4.

Capítulo 3

Coberturas em árvores métricas: frugalidade e flexibilidade

No Capítulo 2 estudamos a estrutura de árvores métricas, introduzimos noções de decomposição e minimalidade e mostramos como toda árvore pode ser reduzida, a custo controlado, a um núcleo simples com poucos galhos profundos. Esses resultados fornecem a base geométrica sobre a qual passamos agora a estudar coberturas determinísticas por bolas fechadas.

Neste capítulo, fixada uma árvore métrica T , nosso objetivo é cobrir T por bolas de raios prescritos, e em particular como equilibrar o *custo* total (a soma dos raios) com a *flexibilidade* na escolha desses raios. Para isso, formalizamos o conjunto de todas as coberturas possíveis de T e provamos três lemas determinísticos que serão reutilizados, em versão probabilística, no Capítulo 4.

Seja, portanto, T uma árvore métrica com métrica intrínseca d_T e comprimento total $|T|$. Para $v \in T$ e $r \geq 0$, denotamos por $B_T(v, r)$ a *bola fechada* de centro v e raio r , isto é,

$$B_T(v, r) := \{x \in T : d_T(x, v) \leq r\}.$$

Uma sequência finita $(r_1, \dots, r_m)$ de reais não negativos é uma *cobertura* de T se existem pontos $v_1, \dots, v_m \in T$ tais que

$$T = \bigcup_{i=1}^m B_T(v_i, r_i).$$

O conjunto de todas as coberturas de T será denotado por $C(T)$. Nas seções seguintes, analisaremos em detalhe três situações fundamentais: coberturas por uma única bola, coberturas cuja soma de raios domina o tamanho de T . No restante deste capítulo, apresentamos e definimos formalmente os conceitos de l-minimalidade de árvores, frugalidade, e flexibilidade, fundamentais neste trabalho.

3.1 Coberturas de uma única bola

O primeiro lema deste capítulo mostra que toda árvore métrica pode ser coberta por uma única bola de raio igual à metade do diâmetro. Em outras palavras, existe sempre um “centro” da árvore a partir do qual nenhum ponto está a mais do que $\text{diam}(T)/2$ de distância.

Lema 3.1.1 (Cobertura por uma bola, [NORIN e TURCOTTE, 2024](#)). *Se T é uma árvore métrica, então existe $y \in T$ tal que*

$$T = B_T\left(y, \frac{\text{diam}(T)}{2}\right).$$

Em particular, $(r) \in C(T)$ para todo $r \geq \text{diam}(T)/2$.

Demonstração. Seja $D := \text{diam}(T)$ o diâmetro de T . Pela definição de diâmetro e pela compacidade de T , existem pontos $u, v \in T$ tais que $d_T(u, v) = D$.

Considere o caminho (curva simples) $T[u, v]$ entre u e v , de comprimento D , e seja y o ponto médio desse caminho, isto é, o ponto tal que

$$d_T(u, y) = d_T(y, v) = \frac{D}{2}.$$

É suficiente mostrar que todo ponto $w \in T$ satisfaz $d_T(w, y) \leq \frac{D}{2}$. Como w é arbitrário, isso implicará que $T \subseteq B_T(y, \frac{D}{2})$, e, como a bola é um subconjunto de T , teremos a igualdade desejada.

Considere a decomposição de T obtida ao remover o ponto y . Como T é uma árvore métrica (conexo e sem ciclos), o conjunto $T \setminus \{y\}$ se decompõe em componentes conexas $C_1, \dots, C_k$; cada conjunto $C_i \cup \{y\}$ é um ramo de T ancorado em y . Em particular, os pontos u e v pertencem a componentes distintas, pois o caminho $T[u, v]$ passa por y e y é o único ponto comum aos dois “lados” do caminho em relação a y .

Seja agora $w \in T$ arbitrário. Então w pertence a alguma componente C_j de $T \setminus \{y\}$. Pelo menos um dos pontos u ou v não está em C_j , pois u e v já pertencem a componentes diferentes. Sem perda de generalidade, podemos supor que $u \notin C_j$.

Nessa situação, qualquer caminho em T ligando u a w é obrigado a passar por y , pois u e w estão em componentes distintas de $T \setminus \{y\}$. Logo o caminho $T[u, w]$ é a concatenação do caminho $T[u, y]$ com o caminho $T[y, w]$, e portanto

$$d_T(u, w) = d_T(u, y) + d_T(y, w) = \frac{D}{2} + d_T(y, w).$$

Suponha agora, para obter uma contradição, que $d_T(w, y) > \frac{D}{2}$. Substituindo essa desigualdade na expressão acima, obtemos

$$d_T(u, w) = \frac{D}{2} + d_T(y, w) > \frac{D}{2} + \frac{D}{2} = D.$$

Mas isso contradiz a escolha de $D = \text{diam}(T)$, que é, por definição, a maior distância entre

dois pontos da árvore. Portanto a suposição $d_T(w, y) > D/2$ é impossível, e concluímos que, para todo $w \in T$ é válido que $d_T(w, y) \leq \frac{D}{2}$. Isso mostra que $T \subseteq B_T(y, \frac{D}{2})$, e como a bola é um subconjunto de T , obtemos a igualdade $T = B_T(y, \frac{D}{2})$.

Finalmente, se $r \geq D/2 = \text{diam}(T)/2$, então vale que $B_T(y, \frac{D}{2}) \subseteq B_T(y, r)$, de modo que (r) também é uma cobertura de T , isto é, $(r) \in \mathcal{C}(T)$. Isso completa a demonstração. $\square$

Este lema diz que, em uma árvore métrica T , sempre existe um “centro” y tal que uma única bola de raio $\text{diam}(T)/2$ cobre T . Em termos geométricos, o ponto y é o ponto médio de um par de pontos mais distantes possível em T ; nesse sentido, ele desempenha o papel de um centro de massa puramente métrico da árvore. O lema afirma que, apesar da possível complexidade da árvore, não é preciso um raio maior do que metade do diâmetro para alcançá-la por completo.

Do ponto de vista deste trabalho, o Lema 3.1.1 serve como caso base para vários argumentos indutivos. Em particular, no próximo lema veremos que, quando a soma de uma família finita de raios é pelo menos $|T|$, sempre é possível escolher centros de modo que as bolas correspondentes cubram toda a árvore. No extremo em que há apenas um raio disponível, esse raio precisa ser pelo menos da ordem de $\text{diam}(T)/2$, recuperando precisamente a situação tratada aqui.

3.2 Um critério de soma de raios

O próximo resultado formaliza um princípio intuitivo de “tamanho versus custo” para coberturas em árvores métricas: se a soma dos raios disponíveis é pelo menos o comprimento total da árvore, então é sempre possível escolher centros adequados de forma que essas bolas cubram toda a árvore. Esse lema será usado repetidamente quando construirmos coberturas por indução, tanto no contexto determinístico deste capítulo quanto nas construções probabilísticas dos capítulos seguintes.

Lema 3.2.1 (Soma dos raios, [NORIN e TURCOTTE, 2024](#)). *Sejam $r_1, \dots, r_k \in \mathbb{R}_{\geq 0}$. Se $|T| \leq \sum_{i=1}^k r_i$, então $(r_1, \dots, r_k) \in \mathcal{C}(T)$.*

Demonstração. A prova seque por indução em k .

Suponha, primeiramente, que $k = 1$ e $|T| \leq r_1$. Como já vimos no Lema 3.1.1, para toda árvore métrica T vale $\text{diam}(T) \leq |T|$. Logo $r_1 \geq |T| \geq \text{diam}(T)$ e, em particular, $r_1 \geq \text{diam}(T)/2$. Pelo Lema 3.1.1, existe $y \in T$ tal que $T = B_T(y, \text{diam}(T)/2) \subseteq B_T(y, r_1)$, de modo que (r_1) é uma cobertura de T , isto é, $(r_1) \in \mathcal{C}(T)$.

Suponha então que $k \geq 2$ e que o enunciado vale para todo inteiro menor que $k' \leq k$, e consideremos $r_1, \dots, r_k \in \mathbb{R}_{\geq 0}$ satisfazendo $|T| \leq \sum_{i=1}^k r_i$.

Se $|T| \leq r_1$, estamos novamente no caso base: como $r_1 \geq |T| \geq \text{diam}(T)$, o Lema 3.1.1 garante que (r_1) cobre T , e então $(r_1, \dots, r_k)$ também é uma cobertura de T .

Portanto, podemos supor que $|T| > r_1$. Agora, pelo Lema 2.2.4, existem árvores T_0 e T_1 que possuem apenas um vértice em comum, e tais que $T = T_0 \cup T_1$ e que T_1 é r_1 -minimal,

isto é, $r_1 \leq |T_1| \leq 2r_1$ e vale que $\text{diam}(T_1) \leq |T_1| \leq 2r_1$, de onde obtemos $r_1 \geq \frac{\text{diam}(T_1)}{2}$. Pelo Lema 3.1.1 aplicado à árvore T_1 , existe um ponto $y \in T_1$ tal que

$$T_1 \subseteq B_T(y, \text{diam}(T_1)/2) \subseteq B_T(y, r_1),$$

o que mostra que o raio r_1 é suficiente para cobrir toda a subárvore T_1 .

Resta então cobrir T_0 . Como $T = T_0 \cup T_1$ e T_0 e T_1 intersectam-se em no máximo um ponto, temos $|T_0| = |T| - |T_1| \leq \left(\sum_{i=1}^k r_i\right) - |T_1|$. Usando $|T_1| \geq r_1$, obtemos $|T_0| \leq \left(\sum_{i=1}^k r_i\right) - r_1 = \sum_{i=2}^k r_i$.

Assim, a árvore T_0 satisfaz a hipótese do lema para os $k-1$ raios $r_2, \dots, r_k$; pela hipótese de indução, existe uma escolha de centros em T_0 tal que $(r_2, \dots, r_k) \in C(T_0)$.

Finalmente, combinando a bola de raio r_1 que cobre T_1 com as bolas de raios $r_2, \dots, r_k$ que cobrem T_0 , obtemos uma coleção de bolas cuja união contém $T_0 \cup T_1 = T$. Portanto $(r_1, \dots, r_k) \in C(T)$, o que conclui o passo indutivo e a prova do lema. $\square$

Do ponto de vista conceitual, o Lema 3.2.1 estabelece um balanço simples entre *tamanho* e *custo*: o comprimento total $|T|$ da árvore é o “tamanho” do objeto a ser coberto, enquanto a soma $\sum_i r_i$ representa o “custo total” disponível em termos de raios. O lema afirma que, em árvores métricas, não há desperdício estrutural: desde que o custo total em raios seja pelo menos o tamanho da árvore, sempre é possível redistribuir esses raios em posições adequadas de modo a cobrir todo o espaço.

3.3 Coberturas por duas bolas em árvores ℓ -minimais

Nesta seção consideramos árvores métricas que são quase minimais para uma única decomposição. Recordemos rapidamente a noção de árvore ℓ -minimal introduzida no Capítulo 2. Uma árvore métrica T é dita ℓ -minimal se $|T| \geq \ell$ e existe uma decomposição $T = T' \cup T''$, em subárvores métricas T' e T'' com interseção em no máximo um ponto, tal que $|T'| \leq \ell$ e $|T''| \leq \ell$.

Além disso, pelo Lema 2.2.3 (núcleo de três folhas), como T é ℓ -minimal existe subárvore $T^* \subset T$ tal que T^* tem exatamente três folhas e um parâmetro $z \geq 0$ tal que cada componente J de $T \setminus T^*$ tem profundidade em T no máximo z e $|T| \geq |T^*| + 4z$. Intuitivamente, T^* é um “núcleo de três ramos” e as componentes restantes são galhos de profundidade controlada.

O próximo lema, devido a Norin e Turcotte, diz que é possível cobrir toda árvore ℓ -minimal com duas bolas cujo custo total é rigidamente controlado, mas com grande liberdade na maneira de repartir esse custo entre os dois raios.

Lema 3.3.1 (Cobertura de duas bolas frugal e flexível, NORIN e TURCOTTE, 2024, Lema 3.3).

Seja T uma árvore métrica ℓ -minimal. Então existe um parâmetro

$$0 \leq a \leq \min \left\{ \frac{\ell}{2} - \frac{|T|}{4}, \frac{|T|}{12} \right\}$$

tal que:

- (i) para todo x com $0 \leq x \leq |T|/4 - 3a$, o par de raios

$$\left(\frac{|T|}{4} - 3a - x, \frac{|T|}{4} + a + x \right)$$

forma uma cobertura de T ;

- (ii) para todo $x \geq |T|/4 - 3a$, o único raio $\frac{|T|}{4} + a + x$ cobre T , isto é, $(\frac{|T|}{4} + a + x) \in C(T)$.

Esboço da prova. A prova completa, com todas as estimativas algébricas, pode ser encontrada em [NORIN e TURCOTTE, 2024](#), Lema 3.3; aqui descrevemos apenas a estrutura geométrica do argumento.

Pelo Lema 2.2.3 do núcleo de três folhas no Capítulo 2, existe uma subárvore $T' \subseteq T$ com exatamente três folhas v_1, v_2, v_3 e um parâmetro $z \geq 0$ tal que:

- todas as componentes J de $T \setminus T'$ têm profundidade em T no máximo z ;
- o comprimento de T satisfaz $|T| \geq |T'| + 4z$.

Denotemos por v_0 o ponto de bifurcação de T' (o vértice de onde saem os três ramos) e sejam $\ell_i := d_T(v_0, v_i)$, $i = 1, 2, 3$, ordenados de forma que $\ell_1 \leq \ell_2 \leq \ell_3$. Assim, $|T'| = \ell_1 + \ell_2 + \ell_3$ e $\text{diam}(T') = \ell_2 + \ell_3$, e, pelos galhos de profundidade z , obtém-se uma estimativa

$$\text{diam}(T) \leq \ell_2 + \ell_3 + 2z.$$

Define-se então

$$a := \max \left\{ 0, \frac{\ell_1 + \ell_2}{2} + z - \frac{|T|}{4} \right\}.$$

Usando as desigualdades acima (em particular $|T| \geq |T'| + 4z$ e a ℓ -minimalidade de T), verifica-se que $0 \leq a \leq \min \left\{ \frac{\ell}{2} - \frac{|T|}{4}, \frac{|T|}{12} \right\}$. Com a fixado, consideramos a família de pares de raios parametrizada por $x \geq 0$:

$$r_1(x) := \frac{|T|}{4} - 3a - x, \quad r_2(x) := \frac{|T|}{4} + a + x.$$

Há dois regimes distintos:

(a) *Regime de duas bolas.* Se $0 \leq x \leq |T|/4 - 3a$, então $r_1(x) \geq 0$ e $r_2(x)$ é suficientemente grande em termos de z e dos comprimentos ℓ_i para que possamos posicionar os centros p_1 e p_2 no segmento $T[v_2, v_3]$ de forma que:

- as bolas $B_T(p_1, r_1(x) - z)$ e $B_T(p_2, r_2(x) - z)$ cubram todo o núcleo T' ;

- ao se adicionar a profundidade z aos raios (isto é, considerar $r_1(x)$ e $r_2(x)$), essas bolas se estendam por todos os galhos complementares de $T \setminus T'$.

Isso mostra que, nesse intervalo de x , o par $(r_1(x), r_2(x))$ define uma cobertura de T , o que prova o item (i).

(b) *Regime de uma bola.* Se $x \geq |T|/4 - 3a$, então $r_2(x)$ cresce e se torna grande o bastante para cobrir T sozinho. Mais precisamente, o limite inferior para x implica

$$r_2(x) = \frac{|T|}{4} + a + x \geq \frac{\ell_2 + \ell_3}{2} + z \geq \frac{\text{diam}(T)}{2},$$

de modo que o Lema 3.1.1 garante que o raio $r_2(x)$ é suficiente para cobrir toda a árvore T . Assim, no regime $x \geq |T|/4 - 3a$, o par degenera em uma única bola, como afirma o item (ii).

Os detalhes algébricos que ligam as desigualdades acima às hipóteses de ℓ -minimalidade podem ser encontrados em [NORIN e TURCOTTE, 2024](#), Lema 3.3, e não são necessários para o uso do lema ao longo desta tese. $\square$

Frugalidade e flexibilidade. O Lema 3.3.1 é importante não apenas pelo fato de garantir uma cobertura por duas bolas, mas pela maneira como controla simultaneamente o *custo total* e a *liberdade de escolha* dos raios.

Primeiro, notemos que a soma dos raios é independente de x :

$$r_1(x) + r_2(x) = \left(\frac{|T|}{4} - 3a - x \right) + \left(\frac{|T|}{4} + a + x \right) = \frac{|T|}{2} - 2a.$$

Esse valor permanece fixo em toda a família de pares $(r_1(x), r_2(x))$ que realmente utilizam duas bolas (regime $0 \leq x \leq |T|/4 - 3a$). Dizemos que a cobertura é *frugal* porque o custo total em raios é rigidamente controlado: independentemente de como repartimos esse custo entre a primeira e a segunda bola, a soma $r_1(x) + r_2(x)$ nunca ultrapassa $\frac{|T|}{2}$, salvo pela pequena assimetria de $2a$.

Por outro lado, a função

$$x \mapsto (r_1(x), r_2(x))$$

é afim em x e parametriza um segmento de reta no plano (r_1, r_2) . À medida que x varia em um intervalo real contínuo, percorremos um intervalo contínuo de pares de raios admissíveis que cobrem a árvore no regime de duas bolas. Em cada coordenada, isso se traduz em um intervalo contíguo de comprimentos possíveis para r_1 e para r_2 . A liberdade de deslocar x sem perder a propriedade de cobertura é o que chamamos de *flexibilidade*: temos um continuum de partições viáveis de um custo total praticamente fixo.

Essa combinação de frugalidade (controle de custo) e flexibilidade (escolhas contínuas de raios) é a principal razão pela qual o Lema 3.3.1 será útil nos capítulos seguintes. Na construção probabilística, ele permite parametrizar coberturas determinísticas com raios

variando em intervalos, o que é essencial para construir coberturas aleatórias com boas propriedades de uniformidade ao longo de toda a árvore.

3.4 Síntese e conexão com o Capítulo 4

Os resultados deste capítulo fornecem a base determinística sobre a qual será construída a análise probabilística do Capítulo 4. O Lema 3.1.1 mostra que, em qualquer árvore métrica, uma única bola de raio $\text{diam}(T)/2$ é suficiente para cobrir toda a árvore, estabelecendo um caso extremo de cobertura “concentrada”. O Lema 3.2.1 complementa essa visão com um princípio de tipo “tamanho versus custo”: sempre que a soma dos raios é pelo menos $|T|$, é possível escolher centros de modo que a união das bolas correspondentes cubra toda a árvore. Finalmente, o Lema 3.3.1 refina esse quadro em árvores ℓ -minimais, exibindo uma família contínua de coberturas por duas bolas que, ao mesmo tempo, mantém o custo total rigidamente controlado e admite grande flexibilidade na repartição dos raios.

No Capítulo 4, essas ideias serão “aleatorizadas”. Em vez de trabalharmos apenas com uma cobertura fixa $(r_1, \dots, r_m) \in C(T)$, consideraremos distribuições de probabilidade ν sobre o espaço de todas as coberturas de T e introduziremos a *medida de expectativa* E_ν , que registra, em média, quantos raios caem em cada intervalo de comprimentos. A partir de E_ν , definiremos o *momento* $m(E_\nu)$, que mede a soma esperada dos raios em uma cobertura aleatória, e a classe de medidas (r, δ) -controladas, que formaliza um tipo de quase-uniformidade essencial para o argumento. Os lemas determinísticos deste capítulo reaparecerão então sob a forma de lemas de colagem e construções paramétricas, permitindo passar de coberturas frugais e flexíveis em núcleos locais a coberturas aleatórias bem comportadas em toda a árvore. Essa passagem é o primeiro passo na ponte entre a teoria determinística de coberturas e o arcabouço probabilístico que culminará no Teorema 5.1.1.

Capítulo 4

Coberturas aleatórias, medida de expectativa e momento

Até este ponto, trabalhamos apenas com coberturas determinísticas de uma árvore métrica T . Nesses casos, escolhemos explicitamente uma coleção de bolas fechadas, cada uma com um centro e um raio específicos, cuja união cobre todos os pontos da árvore. Para estudar o problema do número de queima de maneira mais flexível e robusta, é útil permitir aleatoriedade no processo de seleção dos raios. Em vez de trabalharmos sempre com a mesma cobertura, passamos a considerar um processo que escolhe aleatoriamente entre diferentes coberturas possíveis, cada uma com certa probabilidade. Esta é a ideia central de uma *cobertura aleatória*.

4.1 Coberturas aleatórias e medida de expectativa

Formalmente, seja $C(T)$ o conjunto de todas as coberturas finitas de T . Cada elemento

$$r = (r_1, r_2, \dots, r_m) \in C(T)$$

representa uma cobertura possível, dada pela sequência de raios das bolas que cobrem a árvore. O número de bolas m pode variar: uma cobertura pode usar uma única bola, outra pode usar quatro, e assim por diante.

Uma *cobertura aleatória* é uma regra probabilística que nos diz com que probabilidade escolhemos cada cobertura em $C(T)$. Equivalentemente, é uma distribuição de probabilidade ν em $C(T)$, que atribui, a cada cobertura $r \in C(T)$, um peso $\nu(r)$ representando a probabilidade de o processo produzir exatamente aquela sequência de raios. Em termos intuitivos, ν nos diz quais coberturas são mais frequentes e quais são raras.

Exemplo 1. Suponha que T seja uma árvore métrica que pode ser coberta de duas maneiras:

- por uma única bola de raio 5, representada pela sequência (5);
- por duas bolas de raio 2, representadas pela sequência (2, 2).

Definimos uma distribuição de probabilidade ν em $C(T)$ estabelecendo

$$\nu((5)) = \frac{1}{2} \quad e \quad \nu((2, 2)) = \frac{1}{2},$$

e atribuímos probabilidade 0 a todas as outras coberturas. Nesse caso, ao executar o experimento, há 50% de chance de obtermos a cobertura (5) e 50% de chance de obtermos a cobertura (2, 2). Dizemos que ν é uma distribuição de coberturas aleatórias em $C(T)$.

Uma vez que podemos escolher coberturas ao acaso, surge naturalmente a pergunta: *em média*, como os raios estão distribuídos? Por exemplo, qual é o número esperado de raios cujo comprimento está entre 0 e 3? Para formular essa questão de maneira precisa, introduzimos uma função de contagem simples.

Fixe um intervalo $B \subseteq \mathbb{R}$ (por exemplo, $B = [0, 3]$ como no exemplo acima). Dada uma cobertura $r = (r_1, \dots, r_m)$ com $r_i \in \mathbb{R}$ para $i \in [m]$, definimos

$$\#(B, r) = |\{i : r_i \in B\}|$$

como o número de raios de r que pertencem a B . Por exemplo, se $r = (1, 2, 5)$ e $B = [0, 3]$, então $\#(B, r) = 2$.

Quando permitimos aleatoriedade, a cobertura r é escolhida de acordo com uma distribuição de probabilidade ν em $C(T)$. Assim, $\#(B, r)$ se torna uma variável aleatória: seu valor depende do resultado do experimento. Se quisermos saber *em média* quantos raios caem em B , precisamos calcular o valor esperado de $\#(B, r)$, isto é, a média de $\#(B, r)$ sobre todas as coberturas possíveis, ponderadas por suas probabilidades.

Definição 4.1.1. *Seja ν uma distribuição de probabilidade em $C(T)$. A medida de expectativa associada a ν é a aplicação*

$$E_\nu : \{\text{intervalos de } \mathbb{R}_+\} \longrightarrow \mathbb{R}_+$$

definida, para cada intervalo $B \subset \mathbb{R}_+$, por

$$E_\nu(B) = \mathbb{E}_\nu[\#(B, r)].$$

Na notação acima, $\mathbb{E}_\nu$ indica que o valor esperado é calculado no espaço de probabilidade cujo espaço amostral é $C(T)$, munido da distribuição ν , isto é, quando a cobertura r é escolhida aleatoriamente de acordo com ν . Em uma notação mais compacta, podemos escrever

$$E_\nu(B) = \int_{C(T)} \#(B, r) d\nu(r).$$

Para os propósitos deste trabalho, é suficiente interpretar $E_\nu(B)$ como

“o número esperado de raios que pertencem a B em uma cobertura escolhida aleatoriamente segundo ν ”.

Retomemos o exemplo anterior. Suponha que temos 50% de chance de escolher a cobertura (5) e 50% de chance de escolher a cobertura (2, 2). Consideremos os intervalos $B_1 = [0, 3]$ e $B_2 = [3, 6]$.

- Em $B_1 = [0, 3]$, a cobertura (5) possui 0 raios, enquanto (2, 2) possui 2 raios. Logo,

$$E_v([0, 3]) = \frac{1}{2} \cdot 0 + \frac{1}{2} \cdot 2 = 1.$$

- Em $B_2 = [3, 6]$, a cobertura (5) possui 1 raio, enquanto (2, 2) possui 0 raios. Portanto,

$$E_v([3, 6]) = \frac{1}{2} \cdot 1 + \frac{1}{2} \cdot 0 = \frac{1}{2}.$$

Assim, a medida de expectativa nos diz que, em média, há 1 raio entre 0 e 3 e 0,5 raios entre 3 e 6. Esses valores não precisam ser inteiros, pois representam valores esperados.

Uma situação particularmente simples ocorre quando a distribuição de probabilidade ν está concentrada em coberturas de tamanho fixo m , isto é, quando a probabilidade de selecionar qualquer cobertura com número diferente de m raios é zero.

Mais precisamente, denotemos por

$$C_m(T) = \{ r = (r_1, \dots, r_m) \in C(T) : r \text{ tem exatamente } m \text{ raios} \}$$

o subconjunto de $C(T)$ formado apenas pelas coberturas com m raios. Dizemos que ν tem *suporte* $C_m(T)$ se $\nu(C_m(T)) = 1$, isto é, se $\nu(r) = 0$ para toda cobertura $r \in C(T) \setminus C_m(T)$. Nesse caso, a variável aleatória “número de raios” é constante (vale sempre m), mas os comprimentos individuais dos raios podem variar.

Dada uma distribuição de probabilidade ν e $i \in \{1, \dots, m\}$, definimos a medida de probabilidade ν_i na reta real não negativa como a *distribuição do i -ésimo raio*. Formalmente, para cada intervalo $B \subseteq \mathbb{R}_+$, definimos

$$\nu_i(B) = \nu(\{ r = (r_1, \dots, r_m) \in C_m(T) : r_i \in B \}).$$

Em palavras, $\nu_i(B)$ é a probabilidade de o i -ésimo raio pertencer a B quando a cobertura r é escolhida aleatoriamente segundo ν .

Lema 4.1.2. *Sejam T uma árvore métrica e $m \in \mathbb{N}^+$. Se ν é uma medida de probabilidade em $C(T)$ com suporte $C_m(T)$ e E_ν é a medida de expectativa associada, então, para todo intervalo $B \subseteq \mathbb{R}_+$, vale*

$$E_\nu(B) = \nu_1(B) + \dots + \nu_m(B).$$

Em notação compacta, podemos escrever

$$E_\nu = \nu_1 + \dots + \nu_m.$$

Demonstração. Como ν é suportada em $C_m(T)$, podemos escrever o valor esperado $E_\nu(B) = \mathbb{E}_\nu[\#(B, r)]$ como uma soma finita sobre $C_m(T)$:

$$E_\nu(B) = \sum_{r \in C_m(T)} \#(B, r) \cdot \nu(r).$$

Por definição, temos que $\#(B, r) = |\{i \in [m] : r_i \in B\}|$. Podemos reescrever essa quantidade

como uma soma de indicadores:

$$\#(B, r) = \sum_{i=1}^m \mathbf{1}_{\{r_i \in B\}},$$

onde $\mathbf{1}_{\{r_i \in B\}}$ vale 1 se $r_i \in B$ e 0 caso contrário. Substituindo na expressão de $E_\nu(B)$, obtemos

$$E_\nu(B) = \sum_{r \in C_m(T)} \left(\sum_{i=1}^m \mathbf{1}_{\{r_i \in B\}} \right) \nu(r).$$

Como estamos lidando com somas finitas, podemos trocar a ordem das somas:

$$E_\nu(B) = \sum_{i=1}^m \sum_{r \in C_m(T)} \mathbf{1}_{\{r_i \in B\}} \nu(r).$$

Para cada i , a soma interna é exatamente a probabilidade de o i -ésimo raio pertencer a B , isto é,

$$\sum_{r \in C_m(T)} \mathbf{1}_{\{r_i \in B\}} \nu(r) = \nu(\{r \in C_m(T) : r_i \in B\}) = \nu_i(B).$$

Portanto,

$$E_\nu(B) = \sum_{i=1}^m \nu_i(B),$$

como queríamos demonstrar. □

O Lema 4.1.2 formaliza a ideia de que E_ν reflete o comportamento combinado de todos os raios, sem distinguir de qual bola cada raio origina-se. A medida E_ν pode ser vista como a soma das distribuições marginais $\nu_1, \dots, \nu_m$: para cada intervalo B , o valor $E_\nu(B)$ é simplesmente a soma das probabilidades de que cada coordenada r_i caia em B . Dessa forma, E_ν é uma forma compacta de descrever como a “massa total” de raios se distribui ao longo dos possíveis comprimentos em todas as coberturas aleatórias suportadas em $C_m(T)$.

Em resumo, a medida de expectativa E_ν transforma uma coleção de coberturas aleatórias em um único objeto que nos diz quanto cada faixa de valores de raio é usada, em média. Essa noção é fundamental porque nos permite tirar conclusões sobre o comportamento médio das coberturas, em vez de analisar uma única realização específica. Nas seções seguintes, veremos como extrair de E_ν um parâmetro escalar, o *momento*, e como impor sobre E_ν uma condição de quase uniformidade via medidas (r, δ) -controladas. Esses dois conceitos servirão de ponte entre os argumentos probabilísticos e os limitantes determinísticos do problema do número de queima.

4.2 O momento da medida de expectativa

A medida de expectativa E_ν descreve, para cada intervalo de comprimentos, quantos raios são utilizados em média por uma cobertura aleatória escolhida segundo ν . Em muitos argumentos, porém, é conveniente resumir essa informação em um único número que

quantifique o “tamanho total” dos raios usados. Seguindo (Norin & Turcotte, 2024, Seção 3), introduzimos para isso o *momento da medida de expectativa*, denotado por $m(E_\nu)$.

A ideia é que esse momento deve levar em conta simultaneamente *quantos* raios são usados e quão *grandes* eles são. Raios longos contribuem mais para o alcance da cobertura do que raios curtos, e o momento deve refletir essa diferença.

Definição 4.2.1. *Seja ν uma distribuição de probabilidade em $C(T)$ e seja E_ν a expectativa de medida associada. O momento de E_ν , seguindo (Norin & Turcotte, 2024), é o número real definido por*

$$m(E_\nu) = 2 \int_0^\infty x dE_\nu(x).$$

Embora a notação integral possa parecer abstrata, seu significado é direto. A medida E_ν nos diz quantos raios, em média, caem em cada intervalo da reta real positiva. Multiplicar por x e integrar corresponde a *somar* todas essas contribuições, ponderando cada faixa de comprimentos pelo próprio valor do raio. Em termos heurísticos, podemos pensar nessa integral como a versão contínua da soma discreta

$$m(E_\nu) \approx 2 \sum_i x_i E_\nu([x_i, x_{i+1}]),$$

na qual $E_\nu([x_i, x_{i+1}])$ é o número esperado de raios com comprimento no intervalo $[x_i, x_{i+1}]$.

O fator 2 na definição é uma escolha de normalização adotada em (Norin & Turcotte, 2024) para simplificar a forma dos limitantes analíticos que aparecem na prova do Teorema 4.1. Do ponto de vista probabilístico, a informação essencial está no valor

$$\int_0^\infty x dE_\nu(x),$$

que captura a soma total esperada dos comprimentos dos raios.

No caso em que ν tem suporte em coberturas de tamanho fixo m (como discutido na seção anterior), é possível reescrever $m(E_\nu)$ em termos da soma dos raios da cobertura aleatória.

Proposição 1. *Suponha que ν seja uma medida de probabilidade em $C(T)$ suportada em $C_m(T)$ e seja $(r_1, \dots, r_m)$ uma sequência de raios da cobertura escolhida aleatoriamente segundo ν . Então*

$$m(E_\nu) = 2 \mathbb{E}_\nu[r_1 + \dots + r_m].$$

Demonstração. Pelo Lema 4.1.2, para cada intervalo $B \subseteq \mathbb{R}_+$, temos $E_\nu(B) = \nu_1(B) + \dots + \nu_m(B)$, onde ν_i é a distribuição do i -ésimo raio. Substituindo na definição de $m(E_\nu)$,

$$m(E_\nu) = 2 \int_0^\infty x dE_\nu(x) = 2 \int_0^\infty x d(\nu_1 + \dots + \nu_m)(x).$$

Como a integral é linear, obtemos $m(E_\nu) = 2 \sum_{i=1}^m \int_0^\infty x d\nu_i(x)$. Por definição temos que

$\int_0^\infty x \, d\nu_i(x) = \mathbb{E}_\nu[r_i]$. Logo,

$$m(E_\nu) = 2 \sum_{i=1}^m \mathbb{E}_\nu[r_i] = 2 \mathbb{E}_\nu[r_1 + \dots + r_m].$$

□

A Proposição 1 justifica a interpretação de $m(E_\nu)$ como *o dobro da soma esperada dos raios* em uma cobertura aleatória. Em particular, quanto maiores (ou mais numerosos) forem os raios utilizados em média, maior será o momento; quanto menores e mais localizados forem os raios, menor será $m(E_\nu)$.

Retomemos a distribuição distribuição do Exemplo 1

$$\nu((5)) = 0,5, \quad \nu((2, 2)) = 0,5.$$

A soma total dos raios em cada caso é dada por

$$\text{soma em } (5) = 5, \quad \text{soma em } (2, 2) = 2 + 2 = 4,$$

de modo que

$$\mathbb{E}_\nu[r_1 + \dots + r_m] = 0,5 \cdot 5 + 0,5 \cdot 4 = 4,5.$$

Pela Proposição 1,

$$m(E_\nu) = 2 \times 4,5 = 9.$$

Esse valor mede a “massa total” de raios esperada em uma cobertura típica da distribuição ν .

Ao longo de (Norin & Turcotte, 2024), o momento $m(E_\nu)$ é o parâmetro que aparece nos principais limitantes analíticos: toda a construção de coberturas aleatórias é guiada por estimativas do tipo $m(E_\nu) \leq c |T|$ para constantes c adequadas. Neste trabalho, seguiremos essa mesma ideia: controlar o momento é controlar quanta “energia de cobertura” está disponível para espalhar o fogo ao longo da árvore métrica, preparando o terreno para as desigualdades de concentração que serão usadas na discretização final.

4.3 Medidas (r, δ) -controladas

A seção anterior mostrou como o momento $m(E_\nu)$ quantifica a soma esperada de todos os raios em uma cobertura aleatória. No entanto, esse controle é global: duas distribuições muito diferentes podem ter o mesmo momento, por exemplo uma em que todos os raios são próximos de r e outra em que metade é muito pequena e metade é muito grande. Para construir o argumento probabilístico que leva ao Teorema 5.1.1, precisamos garantir não apenas que a soma total dos raios esteja controlada, mas também que eles não se concentrem de maneira excessiva em uma pequena faixa de comprimentos.

A noção de *medida (r, δ) -controlada* formaliza esse requisito de quase uniformidade. De forma intuitiva, uma medida (r, δ) -controlada é aquela que pode ser escrita como uma

combinação convexa de medidas uniformes em intervalos que sempre se estendem até r e têm comprimento pelo menos δr .

Seja T uma árvore métrica e seja $C(T)$ o espaço de todas as coberturas finitas de T por bolas fechadas, como acima. Seja ν uma medida de probabilidade em $C(T)$ e seja E_ν a medida de expectativa associada. Denotamos por $U[a, r]$ a medida de probabilidade uniforme no intervalo real $[a, r]$.

Definição 4.3.1. Dizemos que ν (ou, de maneira equivalente, E_ν) é (r, δ) -controlada se existem coeficientes não negativos

$$\alpha_1, \dots, \alpha_k \geq 0, \quad \sum_{i=1}^k \alpha_i = 1,$$

e parâmetros

$$a_1, \dots, a_k \in [0, (1 - \delta)r],$$

tais que

$$E_\nu = \sum_{i=1}^k \alpha_i U[a_i, r].$$

Essa decomposição garante duas propriedades importantes:

- **Suporte em $[0, r]$.** Como cada $U[a_i, r]$ é suportada em $[a_i, r] \subseteq [0, r]$, todas as massas de E_ν estão concentradas em raios entre 0 e r . Em particular, não há raios maiores que r .
- **δ -controle.** Para cada i , o intervalo $[a_i, r]$ tem comprimento

$$r - a_i \geq r - (1 - \delta)r = \delta r,$$

isto é, cada componente uniforme se estende por um subintervalo de tamanho pelo menos δr . Isso impede que a massa se concentre em intervalos demasiado curtos.

Em termos intuitivos, cada termo $\alpha_i U[a_i, r]$ representa um “nível” da distribuição: com peso α_i , a medida se comporta como se os raios fossem escolhidos uniformemente em $[a_i, r]$. Como todos esses intervalos terminam em r e têm comprimento mínimo δr , a decomposição impede que E_ν apresente picos muito localizados perto de um único comprimento de raio.

Nas próximas seções deste capítulo (não incluídas aqui), veremos que:

- medidas (r, δ) -controladas continuam (r, δ) -controladas sob operações naturais, como a concatenação de coberturas e certas misturas convexas (os chamados *lemas de colagem*);
- a construção recursiva da prova do Teorema 4.1 produz, a cada etapa, distribuições (r, δ) -controladas com momento limitado;
- esse controle simultâneo de momento e de quase uniformidade é o que permite, mais adiante, aplicar desigualdades de concentração e obter a discretização final em

termos da sequência $(1, 2, \dots, k)$.

Dessa forma, as medidas (r, δ) -controladas ocupam um papel intermediário fundamental: são suficientemente rígidas para garantir uniformidade analítica, mas ainda flexíveis o bastante para serem estáveis sob as operações probabilísticas necessárias na prova de Norin e Turcotte.

4.4 Lemas de colagem para medidas (r, δ) -controladas

O objetivo desta seção é mostrar que medidas (r, δ) -controladas mantêm a propriedade de (r, δ) -controladas ao serem parametrizadas por um intervalo, concatenadas ou combinadas de forma convexa. Esses resultados aparecem como os Lemas 4.2, 4.3 e 4.4 em [NORIN e TURCOTTE, 2024](#) e são a base técnica para a prova do Teorema 5.1.1, a versão fracionária do Teorema 7.1.1

Recordamos também a noção de coberturas “boas” em termos da soma dos raios. Para $l \geq 0$, dizemos que uma cobertura $r = (r_1, \dots, r_m)$ de T é l -boa se

$$\sum_{i=1}^m r_i \leq |T| + l,$$

isto é, se a soma dos raios excede o comprimento de T em, no máximo, l . Denotamos por $C(T, l) \subseteq C(T)$ o subconjunto de coberturas l -boas. No caso $l = 0$, as coberturas de $C(T, 0)$ são exatamente aquelas cuja soma dos raios é, no máximo, $|T|$.

4.4.1 Lema de colagem I: operações básicas em $C(T, l)$

O primeiro resultado (Lema 4.2 em [NORIN e TURCOTTE, 2024](#)) coleta três operações fundamentais:

- (i) parametrização por um intervalo,
- (ii) concatenação de coberturas em uma decomposição de T ,
- (iii) combinação convexa de distribuições;

Em todos os casos, a conclusão é que a medida de expectativa se comporta exatamente da forma esperada, e que a propriedade de ser (r, δ) -controlada é preservada.

Lema 4.4.1 ([NORIN e TURCOTTE, 2024](#)). *Seja T uma árvore métrica.*

1. *Sejam $f_1, \dots, f_m : [0, 1] \rightarrow \mathbb{R}_+$ funções afins tais que, para todo $x \in [0, 1]$, o m -tupla*

$$(f_1(x), \dots, f_m(x))$$

é uma cobertura de T . Para cada $i \in [m]$, defina

$$a_i = \min\{f_i(0), f_i(1)\} \quad e \quad b_i = \max\{f_i(0), f_i(1)\},$$

e seja

$$l = \max \left\{ \sum_{i=1}^m f_i(0), \sum_{i=1}^m f_i(1) \right\} - |T|.$$

Então existe uma medida de probabilidade ν em $C(T, l)$ tal que

$$E_\nu = \sum_{i=1}^m U[a_i, b_i]. \quad (4.1)$$

2. Seja $\{T_1, \dots, T_k\}$ uma decomposição de T (isto é, T é a união disjunta, a menos de fronteiras, das subárvores T_i). Sejam $r, \delta, l_1, \dots, l_k \geq 0$ tais que, para cada $1 \leq i \leq k$, exista uma medida de probabilidade ν_i em $C(T_i, l_i)$ que seja (r, δ) -controlada. Então existe uma medida de probabilidade ν em $C(T, \sum_{i=1}^k l_i)$, também (r, δ) -controlada, tal que

$$m(E_\nu) = \sum_{i=1}^k m(E_{\nu_i}). \quad (4.2)$$

3. Seja $l \geq 0$. Sejam $\nu_0, \dots, \nu_k$ medidas de probabilidade em $C(T, l)$ e $p_0, \dots, p_k \geq 0$ tais que $\sum_{i=0}^k p_i = 1$. Então existe uma medida de probabilidade ν em $C(T, l)$ tal que

$$E_\nu = \sum_{i=0}^k p_i E_{\nu_i}. \quad (4.3)$$

Em termos informais, a parte 1 afirma que, se temos uma família contínua de coberturas indexadas por $x \in [0, 1]$, em que cada raio i varia de forma afim entre dois extremos $f_i(0)$ e $f_i(1)$, então escolher um valor de x uniformemente em $[0, 1]$ produz uma distribuição de coberturas cuja medida de expectativa é a soma das medidas uniformes $U[a_i, b_i]$ nos intervalos percorridos por cada raio. A parte 2 permite colar coberturas independentes de subárvores T_i em uma cobertura de T inteiro, preservando o controle (r, δ) e somando os momentos. Finalmente, a parte 3 diz que podemos tirar uma mistura convexa de distribuições já construídas, e a medida de expectativa resultante é simplesmente a combinação convexa das expectativas.

Demonstração. Apresentamos uma prova detalhada da parte 1 e, em seguida, discutimos brevemente as partes 2 e 3.

Parte 1. Definimos uma aplicação

$$F : [0, 1] \longrightarrow C(T, l), \quad F(x) = (f_1(x), \dots, f_m(x)).$$

Por hipótese, para cada $x \in [0, 1]$ o vetor $F(x)$ é uma cobertura de T . Além disso, como cada f_i é afim, a função F é contínua, logo mensurável.

Equipamos $[0, 1]$ com a medida uniforme $U[0, 1]$, isto é, escolhemos um ponto x em $[0, 1]$ “completamente ao acaso”, de modo que todos os subintervalos de mesmo compri-

mento tenham a mesma probabilidade de serem sorteados. Em seguida, usamos a aplicação

$$F : [0, 1] \rightarrow C(T, l), \quad F(x) = (f_1(x), \dots, f_m(x)),$$

para transformar esse número aleatório x em uma cobertura aleatória $F(x)$ de T .

De maneira intuitiva, o procedimento é:

1. sorteamos $x \in [0, 1]$ uniformemente (usando $U[0, 1]$);
2. calculamos os raios $f_1(x), \dots, f_m(x)$;
3. obtemos assim uma cobertura $F(x) \in C(T, l)$.

A distribuição de probabilidade ν em $C(T, l)$ é precisamente a lei desse experimento: para cada subconjunto $B \subseteq C(T, l)$, o valor $\nu(B)$ é a probabilidade de o procedimento acima produzir uma cobertura que pertença a B .

Formalmente, dizemos que ν é a *imagem* de $U[0, 1]$ pela aplicação F e escrevemos

$$\nu(B) = U[0, 1](F^{-1}(B))$$

para todo conjunto mensurável $B \subseteq C(T, l)$. Aqui, $F^{-1}(B)$ é o conjunto de todos os pontos $x \in [0, 1]$ tais que $F(x) \in B$. Em palavras: $\nu(B)$ é a probabilidade de, ao escolher x uniformemente em $[0, 1]$ e aplicar F , cairmos em alguma cobertura de B .

Como $U[0, 1]$ é uma medida de probabilidade em $[0, 1]$ e F é apenas uma regra determinística que transforma pontos de $[0, 1]$ em coberturas de T , a medida ν obtida dessa forma é automaticamente uma medida de probabilidade em $C(T, l)$.

Para entender E_ν de forma mais concreta, fixemos um intervalo $B \subseteq \mathbb{R}_+$. Lembrando a definição, $E_\nu(B)$ é o *número esperado de raios que caem em B* quando escolhemos uma cobertura aleatória segundo ν .

Dado $x \in [0, 1]$, a cobertura correspondente é

$$F(x) = (f_1(x), \dots, f_m(x)),$$

de modo que o número de raios de $F(x)$ em B pode ser escrito como

$$\#(B, F(x)) = \sum_{i=1}^m \mathbf{1}_{\{f_i(x) \in B\}},$$

onde $\mathbf{1}_{\{f_i(x) \in B\}}$ vale 1 se $f_i(x) \in B$ e 0 caso contrário. Tomando valor esperado em relação à escolha uniforme de $x \in [0, 1]$, obtemos

$$E_\nu(B) = \mathbb{E}_\nu[\#(B, r)] = \mathbb{E}_{x \sim U[0, 1]} \left[\sum_{i=1}^m \mathbf{1}_{\{f_i(x) \in B\}} \right].$$

Como a soma é finita, podemos trocar ordem de soma e esperança:

$$E_v(B) = \sum_{i=1}^m \mathbb{E}_{x \sim U[0,1]} [\mathbf{1}_{\{f_i(x) \in B\}}].$$

Mas a esperança de um indicador é exatamente a probabilidade do evento correspondente. Logo,

$$\mathbb{E}_{x \sim U[0,1]} [\mathbf{1}_{\{f_i(x) \in B\}}] = \mathbb{P}_{x \sim U[0,1]}(f_i(x) \in B).$$

Denotando por ν_i a distribuição do i -ésimo raio (isto é, a lei de $f_i(x)$ quando x é escolhido uniformemente em $[0, 1]$), temos

$$\mathbb{P}_{x \sim U[0,1]}(f_i(x) \in B) = \nu_i(B).$$

Concluimos então que

$$E_v(B) = \sum_{i=1}^m \nu_i(B) \quad \text{para todo intervalo } B \subseteq \mathbb{R}_+,$$

o que em notação de medidas se escreve como

$$E_v = \sum_{i=1}^m \nu_i. \tag{4.4}$$

Ou seja, a medida de expectativa é simplesmente a soma das distribuições marginais dos raios.

Agora, observemos o formato de cada ν_i . A função $f_i : [0, 1] \rightarrow \mathbb{R}_+$ é afim e estritamente monótona (ou constante) em $[0, 1]$, e sua imagem é exatamente o intervalo $[a_i, b_i]$ definido anteriormente. Quando escolhemos x uniformemente em $[0, 1]$ e aplicamos f_i , o resultado percorre $[a_i, b_i]$ de maneira uniforme: intervalos de mesmo comprimento em $[a_i, b_i]$ correspondem a intervalos de mesmo comprimento em $[0, 1]$ via f_i^{-1} .

Em outras palavras, a *imagem* da medida uniforme $U[0, 1]$ pela função afim f_i é a medida uniforme em $[a_i, b_i]$. Escrevendo isso em termos das medidas, temos

$$\nu_i = U[0, 1] \circ f_i^{-1} = U[a_i, b_i]$$

para todo $i \in [m]$.

Substituindo essa expressão em (4.4), obtemos

$$E_v = \sum_{i=1}^m U[a_i, b_i],$$

que é exatamente a identidade desejada em (4.1).

Por fim, verifiquemos a condição de l -bondade. Pelas hipóteses do lema, a soma dos

raios em $F(0)$ e em $F(1)$ é, em cada caso, no máximo $|T| + l$. Como cada f_i é afim, a função

$$x \mapsto \sum_{i=1}^m f_i(x)$$

é também afim em $[0, 1]$ e, portanto, seus valores intermediários nunca ultrapassam o máximo entre os valores nos extremos $x = 0$ e $x = 1$. Assim, para todo $x \in [0, 1]$, vale

$$\sum_{i=1}^m f_i(x) \leq \max \left\{ \sum_{i=1}^m f_i(0), \sum_{i=1}^m f_i(1) \right\} \leq |T| + l.$$

Isso mostra que toda cobertura $F(x)$ tem soma de raios no máximo $|T| + l$, isto é, $F(x) \in C(T, l)$ para todo $x \in [0, 1]$. Como ν é construída a partir dessas coberturas, concluimos que ν é de fato uma medida de probabilidade em $C(T, l)$, o que encerra a demonstração da parte 1 do Lema 4.4.1.

Parte 2. Agora, suponha que T seja a união de subárvores $T_1, \dots, T_k$ que formam uma decomposição. Para cada i , temos uma medida de probabilidade ν_i em $C(T_i, l_i)$, (r, δ) -controlada, isto é, com

$$E_{\nu_i} = \sum_{j=1}^{m_i} \alpha_{i,j} U[a_{i,j}, r] \quad \text{e} \quad a_{i,j} \in [0, (1 - \delta)r].$$

Consideramos agora o produto de todas essas distribuições,

$$\mu = \nu_1 \otimes \dots \otimes \nu_k,$$

que é uma medida de probabilidade no produto $C(T_1, l_1) \times \dots \times C(T_k, l_k)$. Um ponto típico desse produto é um k -tuplo $(r^{(1)}, \dots, r^{(k)})$, em que cada $r^{(i)}$ é uma cobertura de T_i .

Definimos uma aplicação

$$R : C(T_1, l_1) \times \dots \times C(T_k, l_k) \longrightarrow C\left(T, \sum_{i=1}^k l_i\right),$$

que simplesmente concatena os vetores de raios:

$$R(r^{(1)}, \dots, r^{(k)}) = (r_1^{(1)}, \dots, r_{m_1}^{(1)}, r_1^{(2)}, \dots, r_{m_k}^{(k)}).$$

Essa concatenação é uma cobertura de T , porque os centros escolhidos nas T_i cobrem cada subárvore e, portanto, a união delas cobre todo T . Além disso, a soma total dos raios excede $|T|$ em, no máximo, $\sum l_i$, logo a imagem está em $C(T, \sum l_i)$.

Tomamos então ν como a imagem de μ por R . Na prática, isso significa: escolhemos independentemente uma cobertura de cada T_i segundo ν_i , e em seguida colamos todas as

bolas obtidas numa única cobertura de T . A medida de expectativa se soma:

$$E_v = \sum_{i=1}^k E_{v_i},$$

pois cada raio que aparece em alguma T_i entra exatamente uma vez na contagem total. Aplicando a definição do momento,

$$m(E_v) = \sum_{i=1}^k m(E_{v_i}),$$

o que é exatamente (4.2). Como cada E_{v_i} é uma combinação de medidas $U[a_{i,j}, r]$ com $a_{i,j} \leq (1 - \delta)r$, a soma E_v também é, logo v é (r, δ) -controlada.

Parte (c). Nesta parte, partimos de medidas de probabilidade $v_0, \dots, v_k$ em $C(T, l)$ e pesos $p_0, \dots, p_k$ com soma 1. Definimos diretamente

$$v = \sum_{i=0}^k p_i v_i.$$

Isto é, para escolher uma cobertura segundo v , primeiro escolhemos um índice I com $\mathbb{P}(I = i) = p_i$ e, em seguida, escolhemos uma cobertura segundo v_I . A medida de expectativa satisfaz

$$E_v = \sum_{i=0}^k p_i E_{v_i}$$

por linearidade do valor esperado, o que é precisamente (4.3). Como todas as coberturas de suporte das v_i são l -boas, o mesmo vale para v . $\square$

Como consequência, os Lemas 4.4.1(2) e 4.4.1(3) garantem que, uma vez construída uma boa distribuição (r, δ) -controlada em cada pedaço de uma decomposição de T , podemos recombina-las sem perder o controle sobre a medida de expectativa nem sobre o momento.

4.4.2 Lema de colagem II: controle em uma árvore $2(1 - \delta)r$ -minimal

O próximo resultado (Lema 4.3 em Norin–Turcotte) é mais técnico. Ele mostra que, se T é uma árvore métrica “minimal” de comprimento da ordem de $2(1 - \delta)r$, então existe uma distribuição (r, δ) -controlada em $C(T, 0)$ cujo momento é quase ótimo.

Lema 4.4.2 (Lema 4.3 de Norin–Turcotte). *Sejam $r > 0$ e $0 < \delta \leq \frac{1}{2}$. Se T é uma árvore métrica $2(1 - \delta)r$ -minimal, então existe uma medida de probabilidade v em $C(T, 0)$, (r, δ) -controlada, tal que*

$$m(E_v) \leq |T| + \delta r.$$

De forma bastante resumida, a prova do Lema 4.4.2 combina três ingredientes principais:

- o Lema 3.3 (já apresentado no Capítulo 3), que garante que uma árvore l -minimal admite coberturas por *dois* raios cujas somas são, essencialmente, $|T|/2$, mas com uma certa folga e uma família contínua de escolhas de raios;
- a parte (1) do Lema 4.4.1, que transforma essa família contínua de coberturas em uma distribuição de probabilidade, cuja medida de expectativa é uma combinação de medidas uniformes em intervalos $[a, r]$;
- uma análise cuidadosa de três regimes de parâmetros (dependendo da relação entre $|T|$, r e a folga a do Lema 3.3), garantindo em cada caso que os intervalos usados estão contidos em $[0, (1 - \delta)r]$ e que o momento $m(E_\nu)$ não ultrapassa $|T| + \delta r$.

Mais especificamente, fixam-se $l = 2(1 - \delta)r$ e toma-se o parâmetro a dado pelo Lema 3.3 aplicado a T . Dependendo se $|T|/2 - 2a$ é maior ou menor do que $(1 - \delta)r$ e r , a prova constrói, em cada caso, uma família afim de coberturas de T parametrizada por $y \in [0, 1]$, e depois aplica o Lema 4.4.1(1) para obter uma medida ν com

$$E_\nu = \text{soma de medidas uniformes do tipo } U[\alpha, r]$$

com $\alpha \leq (1 - \delta)r$, isto é, (r, δ) -controlada. Em seguida, usa-se a linearidade de $m(\cdot)$ e a fórmula

$$m(U[a, b]) = a + b$$

para mostrar, em cada caso, que $m(E_\nu) \leq |T| + \delta r$. Os detalhes são algébricos e envolvem apenas estimativas das combinações lineares de $|T|$, r e a ; remetemos ao artigo original para a conta completa.

Do ponto de vista conceitual, o Lema 4.4.2 garante que, em cada árvore $2(1 - \delta)r$ -minimal, é possível escolher uma distribuição de coberturas “quase frugal” (momento próximo de $|T|$) e cujo perfil de raios é bem comportado em $[0, r]$.

4.4.3 Lema de colagem III: controle global em qualquer árvore métrica

O passo seguinte é globalizar o controle obtido em uma peça minimal para uma árvore métrica arbitrária, usando uma decomposição em pedaços de comprimento controlado e os lemas de colagem anteriores. Este é o conteúdo do Lema 4.4 em Norin–Turcotte.

Lema 4.4.3 (Lema 4.4 de Norin–Turcotte). *Para todo $0 < \delta \leq \frac{1}{2}$, todo $r > 0$ e toda árvore métrica T , existe uma medida de probabilidade ν em $C(T, r)$, (r, δ) -controlada, tal que*

$$m(E_\nu) \leq (1 + \delta)|T| + 2r.$$

A prova se baseia na seguinte estratégia:

1. Escolhemos $l = 2(1 - \delta)r$. Pelo Lema 2.5, podemos decompor T como

$$T = T_0 \cup T_1 \cup \dots \cup T_k,$$

onde $|T_0| \leq l$ e cada T_i (para $i \geq 1$) é l -minimal.

2. Para cada peça T_i com $i \geq 1$, aplicamos o Lema 4.4.2 e obtemos uma medida (r, δ) -controlada ν_i em $C(T_i, 0)$ tal que

$$m(E_{\nu_i}) \leq |T_i| + \delta r.$$

3. Para o pedaço “pequeno” T_0 , usamos o Lema 3.1.1: como $|T_0| \leq l \leq 2(1 - \delta)r$, o diâmetro de T_0 é no máximo $|T_0|$, de modo que uma única bola de raio $(1 - \delta)r$ cobre T_0 . Ao variar esse raio em $[(1 - \delta)r, r]$ e aplicar novamente o Lema 4.4.1(a), obtemos uma medida (r, δ) -controlada ν_0 em $C(T_0, r - |T_0|) \subseteq C(T_0, r)$ com momento

$$m(E_{\nu_0}) \leq (2 - \delta)r.$$

4. Finalmente, colamos todas essas distribuições usando o Lema 4.4.1(b). Obtemos assim uma medida ν em $C(T, r)$, (r, δ) -controlada, cuja medida de expectativa satisfaz

$$m(E_\nu) \leq \sum_{i=1}^k (|T_i| + \delta r) + (2 - \delta)r \leq |T| + k\delta r + 2r.$$

Como o número de peças k é controlado pelo comprimento de T (mais precisamente, $|T| \geq kr$), obtemos a estimativa afirmada

$$m(E_\nu) \leq (1 + \delta)|T| + 2r.$$

Novamente, o artigo original contém as contas exatas, mas o ponto essencial é que cada T_i contribui um termo $|T_i| + \delta r$ para o momento e que o termo extra proporcional a $k\delta r$ é dominado por $\delta|T|$ justamente porque temos uma cota inferior $|T_i| \geq 2(1 - \delta)r$ para as árvores minimais.

Capítulo 5

O Teorema Fundamental em Árvores Métricas

Neste capítulo combinamos as ferramentas determinísticas desenvolvidas no Capítulo 2 (como reduções estruturais e os critérios de cobertura por bolas) com a linguagem probabilística introduzida no Capítulo 3 (coberturas aleatórias, medida de expectativa e momento). O objetivo é demonstrar o resultado analítico central de (Norin & Turcotte, 2024), que aqui será o teorema principal sobre coberturas aleatórias de uma árvore métrica.

De maneira informal, esse teorema afirma que, sempre que o comprimento total $|T|$ de uma árvore métrica T é suficientemente grande em comparação com um parâmetro de raio $r > 0$, existe uma distribuição de coberturas aleatórias ν cujos raios, em média, se comportam quase como se tivessem sido escolhidos de maneira uniforme no intervalo $[0, r]$. Em outras palavras, a medida de expectativa E_ν associada a ν é dominada por uma medida uniforme em $[0, r]$, com um folga multiplicativa arbitrariamente pequena $(1 + \varepsilon)$, desde que $|T|$ seja grande o bastante em função de ε e r .

No restante do trabalho, esse resulta será o elo entre o mundo contínuo das árvores métricas e o problema discreto do número de queima: a partir dele, será possível construir coberturas discreta quase uniforme em árvores finitas e, por fim, em grafos, levando ao limitante assintótico da conjectura do número de queima.

5.1 Enunciado e interpretação do teorema

Teorema 5.1.1 (NORIN e TURCOTTE, 2024). *Sejam $\varepsilon, r > 0$ e T uma árvore métrica tal que*

$$|T| \geq 24\varepsilon^{-1}r,$$

então existe uma medida de probabilidade em $C(T, r)$ tal que

$$E_\nu \leq (1 + \varepsilon) \frac{|T|}{r} U[0, r].$$

Em particular, E_ν tem suporte em $[0, r]$ e é dominada por uma medida uniforme nesse intervalo.

Esse enunciado é formalmente conciso, mas ao mesmo tempo é bastante denso. A desigualdade

$$E_\nu \leq (1 + \varepsilon) \frac{|T|}{r} U[0, r]$$

deve ser lida como uma comparação entre duas medidas na reta real positiva. Do lado esquerdo, E_ν é a medida de expectativa associada à distribuição de coberturas aleatórias ν : para cada intervalo $B \subseteq [0, r]$, o valor $E_\nu(B)$ representa o número esperado de raios pertencentes a B em uma cobertura escolhida aleatoriamente de acordo com ν , como discutido no Capítulo 3. Do lado direito, temos a medida uniforme $U[0, r]$, multiplicada pelo fator $|T|/r$ e pela constante $(1 + \varepsilon)$.

Intuitivamente, o teorema afirma que existe uma forma de queimar T aleatoriamente com raios em $[0, r]$ de tal maneira que, ao longo de muitas realizações desse processo, a distribuição de raios em $[0, r]$ fica quase plana: nenhum subintervalo recebe "massa" de maneira desproporcional. Mais precisamente, qualquer intervalo $B \subseteq [0, r]$ contém em média, no máximo $(1 + \varepsilon) \frac{|T|}{r} U[0, r](B)$ raios, isto é, um fator $(1 + \varepsilon)$ acima do que ocorreria em uma distribuição perfeitamente uniforme com densidade $\frac{|T|}{r}$.

Em termos do momento $m(E_\nu)$, definido na Seção 3.1, essa desigualdade implica automaticamente um limitante do tipo

$$m(E_\nu) \leq (1 + \varepsilon) m\left(\frac{|T|}{r} U[0, r]\right),$$

de modo que a soma esperada dos raios em uma cobertura aleatória escolhida segundo ν não excedem salvo o fator multiplicativo $(1 + \varepsilon)$, o valor ideal que seria obtido se todos os raios fosse distribuídos de forma perfeitamente uniforme $[0, r]$. Assim, o teorema fornece o tipo exato de quase-uniformidade que será necessário no capítulo seguinte.

5.2 Estratégia de prova

A prova do Teorema 5.1.1 é tecnicamente longa, mas a lógica é essencialmente linear. Nesta seção, descrevemos a estrutura geral do argumento, deixando os detalhes para a demonstração completa na Seção 5.3.

O primeiro passo consiste em tratar o caso em que ε é relativamente grande. Nessa situação, o enunciado é mais fácil de satisfazer, pois a folga multiplicativa $(1 + \varepsilon)$ permite uma aproximação mais grosseira da medida uniforme. Explorando coberturas parametrizadas por $x \in [0, r]$, constrói-se uma distribuição de coberturas simples cuja medida de expectativa já é dominada por um múltiplo da medida uniforme em $[0, r]$. Um ajuste cuidadoso dos parâmetros mostra que, para ε acima de um certo limiar, o enunciado do teorema é automaticamente satisfeito.

Em seguida, o caso geral é obtido por um esquema de indução em um parâmetro inteiro n que controla a ordem de grandeza de ε . Em linhas gerais, fixa-se $n \geq 1$ e mostra-se

que, se o teorema vale para todos os valores de ε maiores ou iguais a $15/(n-1)$, então ele também vale para todo ε no intervalo

$$\frac{15}{n} \leq \varepsilon \leq \frac{15}{n-1}.$$

Dessa forma, partindo do caso base (quando ε é grande o suficiente e baixando sucessivamente o valor de ε , obtém-se a validade do teorema para todo ε .

No passo indutivo, partimos de uma distribuição inicial ν_0 de coberturas que é (r, δ) -controlada em $[0, r]$ e cuja medida de expectativa pode ser decomposta em uma soma de medidas uniformes de cauda, da forma

$$E_{\nu_0} = \sum_i \lambda_i U[a_i, r],$$

com coeficientes, $\lambda_i \geq 0$ e $0 \leq a_i \leq r$. Essa decomposição expressa E_{ν_0} como um empilhamento de "blocos" uniformes que cobrem diferentes faixas de raios dentro de $[0, r]$.

Para cada um desses níveis a_i , aplicamos a hipótese de indução ao intervalo de raios menores ou iguais a a_i . Em outras palavras, construímos, por indução, uma distribuição de coberturas aleatórias cujo comportamento esperado é bem controlado quando usamos apenas raios em $[0, a_i]$. Em seguida, usamos o lema de colagem introduzido no Capítulo 2 para combinar, de forma controlada, essa distribuição em $[0, a_i]$ com a parte correspondente a $[a_i, r]$. O resultado dessa colagem é uma nova distribuição de coberturas em $C(T, r)$ cuja medida de expectativa ainda é uma combinação de medidas uniformes em subintervalos de $[0, r]$.

Por fim, tomamos uma combinação convexa adequada dessas distribuições coladas, ajustando os pesos de maneira que a medida de expectativa resultante E_ν fique dominada exatamente por $(1 + \varepsilon) \frac{|T|}{r} U[0, r]$.

A seguir replicaremos em detalhe a prova de Norin & Turcotte.

5.3 Prova detalhada do Teorema 5.1.1

Demonstração. Suponha inicialmente que $\varepsilon \geq 12/11$. Fixe $k = \lceil |T|/r \rceil$, tal que $k \leq |T|/r + 1$. O Lema 3.2.1 garante que para cada $x \in [0, r]$ a $2k$ -tupla

$$\underbrace{(x, \dots, x)}_{k \text{ vezes}}, \underbrace{(r-x, \dots, r-x)}_{k \text{ vezes}} \in C(T),$$

já que a soma de todas as entradas é $kr \geq |T|$. Portanto, obtemos uma família contínua de coberturas parametrizada por x , cada uma obedecendo as condições necessárias para ser cobertura.

Para transformar essa família de coberturas em uma distribuição de coberturas aleatórias, vamos utilizar o Lema 4.4.1(a). O lema garante que se $f_1, \dots, f_m : [0, 1] \rightarrow \mathbb{R}_+$ são funções afim tais que a tupla $(f_1(t), \dots, f_m(t))$ define uma cobertura de T para todo $t \in [0, 1]$,

e se tomarmos $a_i = \min\{f_i(0), f_i(1)\}$, $b_i = \max\{f_i(0), f_i(1)\}$, e

$$l = \max \left\{ \sum_i f_i(0), \sum_i f_i(1) \right\} - |T|$$

então existe uma distribuição de probabilidade $\nu : C(T) \rightarrow [0, 1]$ com suporte em $C(T, l)$ cuja medida de expectativa satisfaz

$$E_\nu = \sum_i^m U[a_i, b_i].$$

Aplicamos esse lema reparametrizando o intervalo $[0, r]$ em $[0, 1]$ com $t = x/r$. Definimos $2k$ funções

$$f_1(t) = \dots = f_k(t) = rt, \quad \text{e} \quad f_{k+1}(t) = \dots = f_{2k}(t) = r(1-t).$$

Para cada $t \in [0, 1]$, a tupla $(f_1(t), \dots, f_{2k}(t))$ coincide com a família de coberturas descrita anteriormente, garantindo que $(f_1(t), \dots, f_{2k}(t)) \in C(T)$. Calculando as extremidades de cada função obtemos $a_i = 0$ e $b_i = r$ para todo i . Agora, como $\sum_i f_i(0) = \sum_i f_i(1) = kr$, temos

$$l = kr - |T| \geq 0. \quad (5.1)$$

Portanto, pelo Lema 4.4.1(a) existe uma distribuição de probabilidade ν com suporte em $C(T, kr - |T|) \subset C(T, r)$ e tal que

$$E_\nu = \sum_{i=1}^{2k} U[0, r] = 2k \cdot U[0, r].$$

Lembre-se que $C(T, kr - |T|) \subset C(T, r)$, uma vez que, pela definição de k temos $k = \lceil |T|/r \rceil \leq |T|/r + 1$, o que implica $kr - |T| \leq r$. Uma vez que $k \leq |T|/r + 1$, segue que

$$E_\nu \leq 2\left(\frac{|T|}{r} + 1\right)U[0, r]. \quad (5.2)$$

No que segue, mostramos que o lado direito de (5.2) vale no máximo $(1 + \varepsilon)\frac{|T|}{r}U[0, r]$. Primeiramente, expandindo (5.2), obtemos

$$2\left(\frac{|T|}{r} + 1\right) = \frac{|T|}{r}\left(2 + \frac{2r}{|T|}\right). \quad (5.3)$$

Além disso, pela hipótese do teorema, temos $|T| \geq 24\varepsilon^{-1}r$, ou, equivalentemente, $\frac{r}{|T|} \leq \frac{\varepsilon}{24}$. Substituindo em (5.3) obtemos

$$\frac{|T|}{r}\left(2 + \frac{2r}{|T|}\right) \leq \frac{|T|}{r}\left(2\left(1 + \frac{\varepsilon}{24}\right)\right) = 2\left(1 + \frac{\varepsilon}{24}\right)\frac{|T|}{r},$$

o que nos dá

$$E_v \leq 2\left(1 + \frac{\varepsilon}{24}\right)^{\frac{|T|}{r}} U[0, r].$$

Finalmente, afirmamos que como $\varepsilon \geq 12/11$, temos $2(1 + \frac{\varepsilon}{24}) \leq (1 + \varepsilon)$, o que nos dá o resultado desejado. De fato, expandindo os dois lados:

$$2 + \frac{\varepsilon}{12} \leq 1 + \varepsilon \iff 1 \leq \varepsilon - \frac{\varepsilon}{12} = \frac{11}{12}\varepsilon \iff \varepsilon \geq \frac{12}{11}.$$

Concluimos que se $\varepsilon \geq 12/11$, então $E_v \leq (1 + \varepsilon)^{\frac{|T|}{r}} U[0, r]$, como desejado.

Então, podemos assumir que $\varepsilon < 12/11$. Vamos provar, por indução $n \geq 1$ que o enunciado vale para qualquer ε satisfazendo $\varepsilon \geq 15/n$. Observe que, dado $\varepsilon > 0$, podemos escolher $n \geq \lceil 15/\varepsilon \rceil$, ou seja, temos ε tal que $15/n \leq \varepsilon$. Isso implica que o teorema vale para todo $\varepsilon > 0$. O caso base, quando $n \leq 13$, foi verificado anteriormente. Então, podemos assumir que $n \geq 14$ e que o teorema vale para todo $\varepsilon^* \geq 15/(n-1)$. Agora, seja ε tal que

$$\frac{15}{n-1} > \varepsilon \geq \frac{15}{n},$$

e tome

$$\varepsilon' = \varepsilon + \frac{\varepsilon^2}{13}, \quad \delta = \frac{\varepsilon}{8}.$$

Primeiro vamos verificar que ε' é grande o suficiente para que a hipótese de indução seja válida. Usando o fato que $\varepsilon \geq 15/n$,

$$\varepsilon' = \varepsilon\left(1 + \frac{\varepsilon}{13}\right) \geq \frac{15}{n}\left(1 + \frac{15}{13n}\right).$$

É suficiente checar que

$$\frac{15}{n}\left(1 + \frac{15}{13n}\right) \geq \frac{15}{n-1}.$$

De fato, a desigualdade acima é verdadeira quando $n \geq 7.5$. Como $n \geq 14$ concluimos que $\varepsilon' \geq 15/(n-1)$ e portanto o teorema é válido para ε' pela hipótese de indução.

Nesse ponto vamos aplicar o Lema 4.4.3 para os parâmetros

$$\delta = \frac{\varepsilon}{8}, \quad r \leq \frac{\varepsilon}{24}|T|.$$

O lema garante a existência de uma medida ν_0 com suporte em $C(T, r)$, coeficientes $\alpha_1, \dots, \alpha_k \geq 0$ e números reais $a_1, \dots, a_k$ satisfazendo $0 \leq a_i \leq (1 - \delta)r$ para todo i tal que a medida de expectativa de ν_0 apresenta a decomposição

$$E_{\nu_0} = \sum_{i=1}^k \alpha_i U[a_i, r],$$

cujo momento satisfaz o limitante

$$m(E_{v_0}) \leq (1 + \delta)|T| + 2r.$$

Substituindo $\delta = \varepsilon/8$ e $r \leq \frac{\varepsilon}{24}|T|$ na desigualdade acima obtemos

$$m(E_{v_0}) \leq (1 + \frac{5\varepsilon}{24})|T|.$$

Como $\frac{5\varepsilon}{24} \leq \frac{\varepsilon}{4}$ podemos escrever

$$m(E_{v_0}) \leq (1 + \frac{\varepsilon}{4})|T|.$$

Contudo, pela definição de momento e sua linearidade podemos afirmar que

$$m(E_{v_0}) = \sum_{i=1}^k \alpha_i m(U[a_i, r]) = \sum_{i=1}^k \alpha_i (r + a_i).$$

Combinando as duas expressões obtemos

$$\sum_{i=1}^k \alpha_i (r + a_i) \leq (1 + \frac{\varepsilon}{4})|T|.$$

Como o teorema assume que $r \leq \frac{\varepsilon}{24}|T|$ podemos relacionar o tamanho total $|T|$ a cada a_i da seguinte maneira.

Como $a_i \leq r$ e $\varepsilon' \geq \varepsilon$ temos

$$|T| \geq \frac{24r}{\varepsilon} \geq \frac{24a_i}{\varepsilon} \geq \frac{24a_i}{\varepsilon'} \quad \text{para todo } i \in [k].$$

Essa desigualdade garante que para cada par (T, a_i) o teorema é satisfeito mas com um parâmetro maior ε' . Portanto, para cada i , a hipótese de indução pode ser aplicada com o parâmetro ε' em vez de ε e a_i em vez de r .

Logo, pela hipótese de indução, para cada $i \in [k]$ existe uma distribuição de probabilidade ν_i com suporte em $C(T, a_i) \subset C(T, r)$, tal que

$$E_{\nu_i} \leq (1 + \varepsilon') \frac{|T|}{a_i} U[0, a_i].$$

Agora, de posse dessas distribuições de probabilidades $\nu_0, \dots, \nu_k$ suportadas em $C(T, r)$ podemos aplicar o Lema 4.4.1(c) para combiná-las em uma única medida. Para isso vamos definir os coeficientes da soma convexa.

Defina

$$q := (1 + \varepsilon')|T| + \sum_{i=1}^k \frac{\alpha_i a_i^2}{r - a_i}.$$

Os coeficientes da soma convexa são

$$p_0 := \frac{(1 + \varepsilon')|T|}{q}, \quad p_i := \frac{\alpha_i a_i}{(r - a_i)q} \quad (i = 1, \dots, k).$$

Esses coeficientes são não-negativos e satisfazem

$$p_0 + \sum_{i=1}^k p_i = \frac{(1 + \varepsilon')|T| + \sum_{i=1}^k \frac{\alpha_i a_i^2}{r - a_i}}{q} = 1,$$

logo o vetor $(p_0, \dots, p_k)$ é um vetor válido para o Lema 4.4.1(c).

Dessa forma, existe uma medida de probabilidade ν suportada em $C(T, r)$ tal que

$$E_\nu = p_0 E_{\nu_0} + \sum_{i=1}^k p_i E_{\nu_i}$$

Substituindo os parâmetros:

$$\begin{aligned} E_\nu &\leq p_0 \sum_{i=1}^k \alpha_i U[a_i, r] + \sum_{i=1}^k p_i (1 + \varepsilon') \frac{|T|}{a_i} U[0, a_i] \\ &\leq p_0 \sum_{i=1}^k \frac{p_i}{p_0} \frac{|T|}{a_i} (1 + \varepsilon') U[0, a_i] + \alpha_i U[a_i, r] \\ &\leq p_0 \sum_{i=1}^k \left(\frac{\alpha_i a_i^2}{(1 + \varepsilon')|T|(r - a_i)} \cdot (1 + \varepsilon') \frac{|T|}{a_i} U[0, a_i] + \alpha_i U[a_i, r] \right) \\ &\leq p_0 \sum_{i=1}^k \left(\frac{\alpha_i r}{(r - a_i)} \left(\frac{a_i}{r} U[0, a_i] + \frac{r - a_i}{r} U[a_i, r] \right) \right) \end{aligned}$$

Agora, utilizamos o fato de que $U[0, r] = \frac{a_i - 0}{r - 0} U[0, a_i] + \frac{r - a_i}{r - 0} U[a_i, r]$. Assim, podemos escrever que

$$E_\nu \leq p_0 \left(\sum_{i=1}^k \frac{\alpha_i r}{(r - a_i)} \right) U[0, r].$$

Portanto para terminar de provar o teorema basta mostrar que $p_0 \left(\sum_{i=1}^k \frac{\alpha_i r}{(r - a_i)} \right) \leq \frac{(1 + \varepsilon)|T|}{r}$. Para isso vamos substituir p_0 e verificar para quais valores de ε a desigualdade é válida.

$$\begin{aligned}
\frac{(1 + \varepsilon')|T|}{(1 + \varepsilon')|T| + \sum_{i=1}^k \frac{\alpha_i a_i^2}{r - a_i}} \sum_{i=1}^k \frac{\alpha_i r}{r - a_i} &\leq \frac{(1 + \varepsilon)|T|}{r} \\
(1 + \varepsilon') \sum_{i=1}^k \frac{\alpha_i r^2}{r - a_i} &\leq (1 + \varepsilon)|T| + \frac{(1 + \varepsilon)}{(1 + \varepsilon')} \sum_{i=1}^k \frac{\alpha_i a_i^2}{r - a_i} \\
\sum_{i=1}^k \frac{\alpha_i r^2}{r - a_i} &\leq (1 + \varepsilon)|T| + \frac{(1 + \varepsilon)}{(1 + \varepsilon')} \sum_{i=1}^k \frac{\alpha_i a_i^2}{r - a_i}
\end{aligned}$$

Rearranjando o termo da esquerda

$$\begin{aligned}
\sum_{i=1}^k \alpha_i(r + a_i) + \sum_{i=1}^k \alpha_i \frac{a_i^2}{r - a_i} &\leq (1 + \varepsilon)|T| + \frac{(1 + \varepsilon)}{(1 + \varepsilon')} \sum_{i=1}^k \frac{\alpha_i a_i^2}{r - a_i} \\
\sum_{i=1}^k \alpha_i(r + a_i) &\leq (1 + \varepsilon)|T| + \left(\frac{(1 + \varepsilon) - 1}{(1 + \varepsilon')} \right) \sum_{i=1}^k \frac{\alpha_i a_i^2}{r - a_i} \\
\sum_{i=1}^k \alpha_i(r + a_i) + \frac{\varepsilon' - \varepsilon}{1 + \varepsilon'} \sum_{i=1}^k \frac{\alpha_i a_i^2}{r - a_i} &\leq (1 + \varepsilon)|T|
\end{aligned}$$

Agora vamos nos concentrar no segundo termo do lado esquerdo.

Primeiro vamos provar que $a_i^2 \leq \frac{r(r+a_i)}{2}$. Como, $a_i \leq r$, podemos escrever que $ra_i \leq r^2$. Assim, a média entre de ra_i e r^2 deve ser maior que ra_i . Então, vale que $ra_i \leq \frac{r^2 + ra_i}{2}$. Contudo, como $a_i^2 \leq ra_i$ pode escrever que $a_i^2 \leq \frac{r(r+a_i)}{2}$. Dividindo ambos os lados por $r - a_i$ e aplicando que $a_i \leq (1 - \delta)r$ obtemos que $\frac{a_i^2}{r - a_i} \leq \frac{r + a_i}{2\delta}$. Assim, vale para o segundo termo da desigualdade o seguinte:

$$\frac{\varepsilon' - \varepsilon}{1 + \varepsilon} \sum_{i=1}^k \alpha_i \frac{a_i^2}{r - a_i} \leq \frac{\varepsilon' - \varepsilon}{1 + \varepsilon} \frac{1}{2\delta} \sum_{i=1}^k \alpha_i(r + a_i).$$

Substituindo os valores de ε' e δ obtemos

$$\frac{\varepsilon' - \varepsilon}{1 + \varepsilon} \sum_{i=1}^k \alpha_i \frac{a_i^2}{r - a_i} \leq \frac{4\varepsilon}{13} \sum_{i=1}^k \alpha_i(r + a_i).$$

Substituindo na desigualdade principal no lugar do segundo termo obtemos

$$\left(1 + \frac{4\varepsilon}{13}\right) \sum_{i=1}^k \alpha_i(r + a_i) \leq (1 + \varepsilon)|T|.$$

Contudo, provamos acima que $\sum_{i=1}^k \alpha_i(r + a_i) \leq (1 + \frac{\varepsilon}{4})|T|$. Assim, a desigualdade que estamos investigando se torna

$$(1 + \frac{4\varepsilon}{13})(1 + \frac{\varepsilon}{4})|T| \leq (1 + \varepsilon)|T|.$$

É fácil verificar que a desigualdade vale para todo $\varepsilon \leq 2$ e portanto vale para nosso $\varepsilon < 15/(n - 1)$ com $n \geq 14$. Logo, podemos escrever que

$$Ev \leq p_0(\sum_{i=1}^k \frac{\alpha_i r}{(r - a_i)})U[0, r] \leq \frac{(1 + \varepsilon)|T|}{r}U[0, r].$$

Ou seja, por indução, o teorema vale para todo $n \geq 1$ e consequentemente para todo $\varepsilon > 0$. □

Capítulo 6

Concentração, Arredondamento e Passagem ao Caso Discreto

Neste capítulo apresentamos em detalhes a demonstração do Teorema 6.2.1, que constitui o elo final entre a teoria fracionária desenvolvida no Teorema 5.1.1 e a forma discreta desejada para a Conjectura do Número de Queima. O objetivo é mostrar que, sob uma hipótese de tamanho subquadrático para uma árvore métrica T , a sequência canônica de raios $(1, 2, \dots, k)$ já é suficiente para cobrir T .

A prova é probabilística e baseia-se na construção de coberturas aleatórias quase uniformes, como no Teorema 5.1.1, seguida de um argumento de concentração que garante que, com probabilidade positiva, nenhum subintervalo curto de raios recebe “massa demais”. A partir dessa realização favorável, fazemos uma etapa puramente combinatória: concatenamos as coberturas locais, discretizamos os raios e, por fim, os reorganizamos até obter exatamente a sequência $(1, 2, \dots, k)$.

Começamos recordando duas desigualdades de concentração que serão usadas de forma essencial: a desigualdade de Markov e a desigualdade de Hoeffding.

6.1 Desigualdades de concentração

6.1.1 Desigualdade de Markov

A desigualdade de Markov é a forma mais elementar de estimar a probabilidade de que uma variável aleatória não negativa assuma valores muito grandes em função de sua esperança. Embora seja bastante fraca em geral, ela é suficiente no nosso contexto para controlar a contribuição de um intervalo específico de raios, e serve como ponto de partida para o argumento de concentração.

Teorema 6.1.1 (Desigualdade de Markov, ALON e SPENCER, 2016). *Se $X \geq 0$ é uma variável aleatória e $a > 0$, então*

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[X]}{a}.$$

Em palavras, a desigualdade afirma que a probabilidade de X ultrapassar um limiar a é no máximo a razão entre o valor esperado $E[X]$ e esse limiar. Quando sabemos que $E[X]$ é significativamente menor que a , obtemos uma boa cota superior para $P(X \geq a)$. No nosso caso, X será um contador do número de raios em um pequeno intervalo de comprimentos, e a desigualdade dirá que, em média, esse número tende a ser menor que o valor “ideal” que gostaríamos de impor.

6.1.2 Desigualdade de Hoeffding

A desigualdade de Hoeffding é uma forma típica de desigualdade do tipo Chernoff: ela fornece um decaimento exponencial para a probabilidade de grandes desvios da média quando somamos variáveis aleatórias independentes e uniformemente limitadas. Essa ferramenta será usada para reforçar a estimativa de Markov e controlar simultaneamente muitos intervalos distintos de raios.

Teorema 6.1.2 (Desigualdade de Hoeffding, [HOEFFDING, 1963](#)). *Se $X_1, \dots, X_m$ são variáveis aleatórias independentes com valores em $[a, b]$, se $X = \sum_{i=1}^m X_i$ e $t > 0$, então*

$$P(X \geq E[X] + t) \leq \exp\left(-\frac{2t^2}{m(b-a)^2}\right).$$

A interpretação é a seguinte: se cada X_i está contido em um intervalo fixo $[a, b]$, então a probabilidade de que a soma X exceda a sua esperança por uma margem t decai exponencialmente em t^2 e em m . No contexto deste capítulo, tomaremos X_i como a contribuição de uma partição T_i para o número de raios em um certo intervalo, e aplicaremos a desigualdade para concluir que, com probabilidade muito próxima de 1, nenhum intervalo curto recebe mais do que um certo número de raios.

6.2 Enunciado e interpretação do Teorema 5.3

Recordamos agora o enunciado central deste capítulo, que aparece em [NORIN e TURCOTTE, 2024](#), Teorema 5.3 e que será demonstrado na sequência. Ele estabelece uma condição suficiente para que a sequência de raios inteiros $(1, 2, \dots, k)$ constitua uma cobertura de uma árvore métrica de tamanho subquadrático.

Teorema 6.2.1 (Teorema 5.3, Norin–Turcotte). *Para todo $\varepsilon > 0$, existe uma constante $K = K_{5.3}(\varepsilon)$ tal que, se $k \in \mathbb{N}$ satisfaz $k \geq K$ e T é uma árvore métrica com $|T| \leq (1 - \varepsilon)k^2$, então a sequência $(1, 2, \dots, k)$ é uma cobertura de T .*

O parâmetro $\varepsilon > 0$ mede uma folga em relação ao limite quadrático: exigimos que $|T|$ seja estritamente menor que k^2 por um fator multiplicativo fixo $1 - \varepsilon$. Para cada valor de ε fixado, o teorema assegura a existência de um limiar $K_{5.3}(\varepsilon)$ a partir do qual, sempre que $k \geq K_{5.3}(\varepsilon)$ e T tiver comprimento total $|T| \leq (1 - \varepsilon)k^2$, a sequência canônica de raios inteiros $(1, 2, \dots, k)$ já cobre toda a árvore.

Do ponto de vista da dinâmica de queima de grafos, este resultado diz que, quando traduzimos o problema para modelo contínuo de árvores métricas, a família de raios mais natural possível (todas as inteiras de 1 a k) é assintoticamente suficiente para queimar

qualquer árvore “não muito grande” em comparação com k^2 . Esse é o passo que permite, mais adiante, conectar o teorema fracionário obtido em 5.1.1 com o enunciado discreto original sobre grafos finitos.

6.3 Demonstração do Teorema 5.3

Passamos agora à prova do Teorema 6.2.1. A estratégia segue fielmente **NORIN e TURCOTTE, 2024** e pode ser descrita, em linhas gerais, da seguinte forma.

Primeiro, fixamos parâmetros auxiliares N , λ e P , que serão usados para controlar a uniformidade da distribuição de raios em pequenos intervalos. Em seguida, decompomos a árvore métrica T em subárvores $T_1, \dots, T_m$ de tamanho controlado por meio do Lema 2.2.5. Em cada T_i , aplicamos o Teorema 5.1.1 com um parâmetro ε_i adequado, obtendo uma cobertura aleatória quase uniforme com raios em $[0, r]$, onde $r \approx k$.

A partir dessas coberturas aleatórias, definimos variáveis aleatórias $Z_i(\alpha)$ que contam quantos raios em T_i caem em um pequeno intervalo I_α de comprimentos de ordem k/N . A desigualdade (6.1) mostra que a esperança da soma $\sum_i Z_i(\alpha)$ é estritamente menor que o número “ideal” k/N de raios por intervalo. Com isso em mãos, aplicamos a desigualdade de Markov para o intervalo inicial e a desigualdade de Hoeffding para os demais intervalos, obtendo uma cota global para a probabilidade de que algum intervalo ultrapasse o limite k/N .

Como essa probabilidade é estritamente menor que 1, conclui-se que existe uma escolha determinística das coberturas locais $r_1, \dots, r_m$ com a seguinte propriedade: nenhum intervalo curto contém demasiados raios. Concatenando essas coberturas e realizando um procedimento de “empurrar para a direita” e discretizar, obtemos uma cobertura por raios inteiros distintos no intervalo $[k/N, k]$. Finalmente, completamos essa família até a sequência inteira $(1, 2, \dots, k)$, o que termina a demonstração.

Demonstração. Podemos supor $0 < \varepsilon < 1$. Escolhemos $N \in \mathbb{N}$ suficientemente grande e definimos

$$\lambda := 1 - \frac{\left(1 + \frac{1}{N}\right)(1 - \varepsilon)}{\left(1 - \frac{1}{N}\right)^2}.$$

Quando N cresce, o fator $\frac{\left(1 + \frac{1}{N}\right)(1 - \varepsilon)}{\left(1 - \frac{1}{N}\right)^2}$ tende a $1 - \varepsilon$, de modo que

$$\lim_{N \rightarrow \infty} \lambda = 1 - (1 - \varepsilon) = \varepsilon > 0.$$

Assim, para N grande o suficiente, λ é positivo.

Com N e $\lambda > 0$ fixos, escolhemos um inteiro $P \geq 1$ tal que

$$N \exp\left(-\frac{\lambda^2}{24N^4(1 - \varepsilon)^2}P\right) < \lambda.$$

A função do lado esquerdo é contínua e decrescente em P , tendendo a 0 quando $P \rightarrow \infty$;

portanto sempre existe um P que satisfaz a desigualdade. Definimos então

$$D = 24N \quad \text{e} \quad K = \frac{PD}{1 - \varepsilon}.$$

Essas definições são imediatas e não impõem novas restrições.

Assumimos, sem perda de generalidade, que

$$|T| = (1 - \varepsilon)k^2 \geq PDk.$$

Se essa desigualdade não fosse satisfeita, poderíamos estender a árvore métrica T . Nesse contexto, “estender” significa adicionar um pequeno segmento a uma folha de T , isto é, unir a T um intervalo adicional de comprimento

$$\Delta = PDk - |T|.$$

O resultado é uma nova árvore métrica T' com $|T'| = |T| + \Delta = PDk$. Como estamos apenas interessados na existência de uma cobertura, podemos trabalhar com T' e, ao final, restringir de volta a T .

Aplicando o Lema 2.2.5, obtemos uma decomposição da árvore métrica T em subárvores métricas

$$T = T_1 \cup T_2 \cup \dots \cup T_m,$$

disjuntas, tais que

$$Dk \leq |T_i| \leq 3Dk \quad \text{para todo } i \in \{1, \dots, m\}.$$

Somando as desigualdades, segue que

$$mDk \leq |T| \leq 3mDk.$$

Como assumimos que $|T| \geq PDk$, obtemos

$$PDk \leq 3mDk \quad \implies \quad m \geq \frac{P}{3}.$$

Portanto, a árvore métrica T pode ser particionada em m subárvores, todas de tamanho controlado, com número de partições proporcional a P .

Fixamos

$$r = \left(1 - \frac{1}{N}\right)k.$$

Para cada subárvore métrica T_i da decomposição escolhemos

$$\varepsilon_i := \frac{24r}{|T_i|}.$$

Por construção, $|T_i| = 24r/\varepsilon_i$, de modo que podemos aplicar o Teorema 5.1.1 em cada T_i .

Consequentemente, existe uma distribuição de probabilidade v_i em $C(T_i, r)$ tal que

$$E_{v_i} \leq \left(1 + \varepsilon_i\right) \frac{|T_i|}{r} U[0, r].$$

Como $|T_i| \geq Dk = 24Nk$ e $r = (1 - \frac{1}{N})k$, temos

$$\varepsilon_i = \frac{24(1 - \frac{1}{N})k}{|T_i|} \leq \frac{24(1 - \frac{1}{N})k}{24Nk} = \frac{1 - \frac{1}{N}}{N} \leq \frac{1}{N},$$

e, portanto,

$$E_{v_i} \leq \left(1 + \frac{1}{N}\right) \frac{|T_i|}{r} U[0, r].$$

Seja r_i uma cobertura aleatória de T_i com raios em $[0, r]$, escolhida de acordo com a lei v_i , e suponha que as escolhas $r_1, \dots, r_m$ são independentes. Para controlar quantos raios caem em um intervalo pequeno, introduzimos um parâmetro

$$\alpha \in \left[0, 1 - \frac{2}{N}\right]$$

e o intervalo

$$I_\alpha := [\alpha k, (\alpha + \frac{1}{N})k].$$

Como $r = (1 - \frac{1}{N})k$ e $\alpha \leq 1 - \frac{2}{N}$, temos $\alpha k \geq 0$ e

$$(\alpha + \frac{1}{N})k \leq (1 - \frac{1}{N})k = r,$$

logo $I_\alpha \subset [0, r]$.

Definimos então a variável aleatória

$$Z_i(\alpha) := \#(I_\alpha, r_i),$$

isto é, $Z_i(\alpha)$ conta o número de raios do vetor r_i que pertencem ao intervalo I_α .

Pela definição de medida de expectativa, podemos escrever

$$\mathbb{E}[Z_i(\alpha)] = E_{v_i}(I_\alpha) \leq (1 + \varepsilon_i) \frac{|T_i|}{r} U[0, r](I_\alpha).$$

Como $U[0, r]$ é a medida uniforme em $[0, r]$, a massa de I_α é proporcional ao comprimento do intervalo. Em particular,

$$U[0, r](I_\alpha) = \frac{|I_\alpha|}{r} = \frac{(\frac{1}{N})k}{r} = \frac{(\frac{1}{N})k}{(1 - \frac{1}{N})k} = \frac{1}{N(1 - \frac{1}{N})}.$$

Substituindo,

$$\mathbb{E}[Z_i(\alpha)] \leq (1 + \varepsilon_i) \frac{|T_i|}{r} \cdot \frac{1}{N(1 - \frac{1}{N})} = (1 + \varepsilon_i) \frac{|T_i|}{N(1 - \frac{1}{N})^2 k}.$$

Pelo limite anterior $\varepsilon_i \leq \frac{1}{N}$, obtemos

$$\mathbb{E}[Z_i(\alpha)] \leq \left(1 + \frac{1}{N}\right) \frac{|T_i|}{N\left(1 - \frac{1}{N}\right)^2 k}.$$

Somando sobre $i = 1, \dots, m$ usando $|T| = \sum_i |T_i| = (1 - \varepsilon)k^2$ e lembrando que

$$1 - \lambda = \frac{\left(1 + \frac{1}{N}\right)(1 - \varepsilon)}{\left(1 - \frac{1}{N}\right)^2},$$

escrevemos

$$\mathbb{E}\left[\sum_{i=1}^m Z_i(\alpha)\right] \leq \left(1 + \frac{1}{N}\right) \frac{|T|}{N\left(1 - \frac{1}{N}\right)^2 k} = \frac{\left(1 + \frac{1}{N}\right)(1 - \varepsilon)}{\left(1 - \frac{1}{N}\right)^2} \cdot \frac{k}{N} = \frac{1 - \lambda}{N} k.$$

Portanto,

$$\mathbb{E}\left[\sum_{i=1}^m Z_i(\alpha)\right] \leq \frac{1 - \lambda}{N} k, \quad \alpha \in \left[0, 1 - \frac{2}{N}\right]. \quad (6.1)$$

Em palavras, cada intervalo pequeno I_α (de largura k/N) contém, em média, no máximo $(1 - \lambda)k/N$ raios quando agregamos todas as partições T_i .

Passo probabilístico: Markov e Hoeffding. Aplicamos agora desigualdades de concentração às variáveis aleatórias $Z_i(\alpha)$.

Primeiro, tomamos $\alpha = 0$ em (6.1) e usamos a desigualdade de Markov (Teorema 6.1.1). Obtemos

$$\mathbb{P}\left(\sum_{i=1}^m Z_i(0) \geq \frac{k}{N}\right) \leq \frac{\mathbb{E}\left[\sum_{i=1}^m Z_i(0)\right]}{k/N} \leq \frac{(1 - \lambda)k/N}{k/N} = 1 - \lambda.$$

Esta desigualdade vale para qualquer α , mas para $\alpha > 0$ precisaremos de um controle mais forte, via uma desigualdade do tipo Chernoff (Hoeffding, Teorema 6.1.2).

Seja agora $\alpha \geq \frac{1}{N}$. Como r_i é uma cobertura r -boa de T_i , a soma dos raios em r_i satisfaz

$$\|r_i\|_1 \leq |T_i| + r.$$

Além disso, cada vez que contamos um raio em $Z_i(\alpha)$, esse raio é pelo menos αk . Assim,

$$Z_i(\alpha) \cdot (\alpha k) \leq \|r_i\|_1 \leq |T_i| + r.$$

Usando $|T_i| \leq 3Dk$ e $r = (1 - \frac{1}{N})k \leq k$, obtemos

$$|T_i| + r \leq 3Dk + k \leq (3D + 1)k \leq 4Dk,$$

pois $D = 24N \geq 1$. Portanto

$$Z_i(\alpha) \alpha k \leq 4Dk \implies 0 \leq Z_i(\alpha) \leq \frac{4D}{\alpha}.$$

Como $\alpha \geq \frac{1}{N}$, temos $\frac{1}{\alpha} \leq N$ e, usando ainda $|T| \geq mDk$ e $|T| = (1 - \varepsilon)k^2$, obtemos

$$\frac{4D}{\alpha} \leq 4DN \leq \frac{4N|T|}{mk} = \frac{4N(1 - \varepsilon)k}{m}.$$

Logo,

$$0 \leq Z_i(\alpha) \leq \frac{4N(1 - \varepsilon)k}{m} \quad \text{para todo } i \in \{1, \dots, m\}, \alpha \geq \frac{1}{N}.$$

Aplicamos agora a desigualdade de Hoeffding (Teorema 6.1.2) às variáveis independentes $Z_1(\alpha), \dots, Z_m(\alpha)$, todas limitadas no intervalo $[0, B]$ com

$$B := \frac{4N(1 - \varepsilon)k}{m}.$$

Tomamos $t := \frac{\lambda k}{N}$ e usamos (6.1):

$$\begin{aligned} \mathbb{P}\left(\sum_{i=1}^m Z_i(\alpha) \geq \frac{k}{N}\right) &= \mathbb{P}\left(\sum_{i=1}^m Z_i(\alpha) \geq \mathbb{E}\left[\sum_{i=1}^m Z_i(\alpha)\right] + \left(\frac{k}{N} - \frac{1 - \lambda}{N}k\right)\right) \\ &= \mathbb{P}\left(\sum_{i=1}^m Z_i(\alpha) \geq \mathbb{E}\left[\sum_{i=1}^m Z_i(\alpha)\right] + t\right) \\ &\leq \exp\left(-\frac{2t^2}{mB^2}\right) \\ &= \exp\left(-\frac{2(\lambda k/N)^2}{m(4N(1 - \varepsilon)k/m)^2}\right) \\ &= \exp\left(-\frac{\lambda^2 m}{8N^4(1 - \varepsilon)^2}\right). \end{aligned}$$

Como $m \geq P/3$, segue que

$$\mathbb{P}\left(\sum_{i=1}^m Z_i(\alpha) \geq \frac{k}{N}\right) \leq \exp\left(-\frac{\lambda^2}{8N^4(1 - \varepsilon)^2} \cdot \frac{P}{3}\right) = \exp\left(-\frac{\lambda^2}{24N^4(1 - \varepsilon)^2}P\right),$$

para todo $\alpha \in [\frac{1}{N}, 1 - \frac{2}{N}]$.

Passagem ao caso determinístico (união). Definimos, para $j \in \{0, 1, \dots, N - 2\}$, os intervalos

$$I_j := \left[\frac{j}{N}k, \frac{j+1}{N}k\right].$$

Note que $I_0 = I_0$ corresponde a $\alpha = 0$, enquanto I_j com $j \geq 1$ corresponde a $\alpha = j/N \geq 1/N$.

Pelo caso $\alpha = 0$ e pela desigualdade de Markov acima, temos

$$\mathbb{P}\left(\sum_{i=1}^m Z_i(0) \geq \frac{k}{N}\right) \leq 1 - \lambda.$$

Para cada $j \in \{1, \dots, N-2\}$, aplicando a desigualdade de Hoeffding com $\alpha = j/N$ obtemos

$$\mathbb{P}\left(\sum_{i=1}^m Z_i\left(\frac{j}{N}\right) \geq \frac{k}{N}\right) \leq \exp\left(-\frac{\lambda^2}{24N^4(1-\varepsilon)^2}P\right).$$

Pelo princípio da união,

$$\begin{aligned} \mathbb{P}\left(\exists j \in \{0, \dots, N-2\} \text{ tal que } \sum_{i=1}^m Z_i\left(\frac{j}{N}\right) \geq \frac{k}{N}\right) &\leq \sum_{j=0}^{N-2} \mathbb{P}\left(\sum_{i=1}^m Z_i\left(\frac{j}{N}\right) \geq \frac{k}{N}\right) \\ &< (1 - \lambda) + N \exp\left(-\frac{\lambda^2}{24N^4(1-\varepsilon)^2}P\right) \\ &< (1 - \lambda) + \lambda = 1, \end{aligned}$$

pela escolha de P . Portanto, a probabilidade de que *nenhum* dos eventos

$$\left\{\sum_{i=1}^m Z_i\left(\frac{j}{N}\right) \geq \frac{k}{N}\right\}, \quad j = 0, \dots, N-2,$$

ocorra é estritamente positiva. Logo, existe uma escolha determinística de coberturas

$$\mathbf{r}^1, \dots, \mathbf{r}^m$$

de $T_1, \dots, T_m$ respectivamente, todas com raios em $[0, r]$, tal que para cada $j \in \{0, 1, \dots, N-2\}$ temos

$$\sum_{i=1}^m Z_i\left(\frac{j}{N}\right) < \frac{k}{N}.$$

Concatenação e discretização dos raios. Seja $\mathbf{r}$ a concatenação das coberturas $\mathbf{r}^1, \dots, \mathbf{r}^m$. Os raios de $\mathbf{r}$ pertencem a $[0, r]$ e, pela propriedade acima, para cada $j \in \{0, 1, \dots, N-2\}$ o número de raios de $\mathbf{r}$ que pertence a

$$I_j = \left[\frac{j}{N}k, \frac{j+1}{N}k\right]$$

é estritamente menor que $\frac{k}{N}$. Em particular,

$$\#(I_j \cap \mathbf{r}) < \frac{k}{N} \implies \#(I_j \cap \mathbf{r}) \leq \left\lfloor \frac{k}{N} \right\rfloor.$$

Observe que o intervalo I_j tem comprimento k/N , logo contém no máximo $\left\lfloor \frac{k}{N} \right\rfloor$ inteiros.

Por outro lado, o intervalo seguinte

$$I_{j+1} = \left[\frac{j+1}{N}k, \frac{j+2}{N}k \right]$$

contém pelo menos $\lfloor \frac{k}{N} \rfloor$ inteiros. Assim, para cada j existe uma injeção

$$\varphi_j : R_j \longrightarrow I_{j+1} \cap \mathbb{Z},$$

onde

$$R_j := \{r \in \mathbf{r} : r \in I_j\}$$

é o conjunto de raios de $\mathbf{r}$ que caem em I_j . Intuitivamente, vamos “empurrar” cada raio de I_j para um inteiro distinto no intervalo seguinte I_{j+1} .

Mais explicitamente, seja $R_j = \{r_0, \dots, r_\ell\}$ com $r_0 \leq \dots \leq r_\ell$, e seja s o menor inteiro em I_{j+1} . Como $\ell + 1 = |R_j| \leq \lfloor k/N \rfloor$ e $I_{j+1} \cap \mathbb{Z}$ contém pelo menos $\lfloor k/N \rfloor$ inteiros, podemos definir

$$\varphi_j(r_i) := s + i, \quad i = 0, \dots, \ell,$$

obtendo uma injeção $R_j \rightarrow I_{j+1} \cap \mathbb{Z}$.

Substituindo, para cada j , os raios de $\mathbf{r}$ que pertencem a I_j pelos inteiros correspondentes $\varphi_j(r)$ em I_{j+1} , obtemos uma nova cobertura $\mathbf{r}'$ de T . Cada raio é aumentado em, no máximo, o comprimento de um intervalo I_j , isto é, em no máximo k/N . Como aumentar raios só pode aumentar a região coberta, $\mathbf{r}'$ continua sendo uma cobertura de T .

Além disso, por construção:

- para cada j , os raios de $\mathbf{r}'$ que pertencem a I_{j+1} são inteiros distintos (pois φ_j é injetiva), e
- raios provenientes de intervalos distintos I_j são enviados para intervalos seguintes distintos I_{j+1} .

Logo, todos os raios de $\mathbf{r}'$ são inteiros distintos, e, como o menor intervalo de chegada é $I_1 = [k/N, 2k/N]$ e o maior é $I_{N-1} = [(N-1)k/N, k]$, temos

$$\mathbf{r}' \subset \left[\frac{k}{N}, k \right] \cap \mathbb{Z}.$$

Em particular, o conjunto de raios de $\mathbf{r}'$ é um subconjunto de $\{1, 2, \dots, k\}$, e $\mathbf{r}'$ é uma cobertura de T . Se algum inteiro em $\{1, 2, \dots, k\}$ não aparecer como raio de $\mathbf{r}'$, podemos simplesmente adicioná-lo como novo raio (escolhendo centros arbitrários), o que só pode aumentar a região coberta. Assim, obtemos uma nova cobertura cujos raios são exatamente os inteiros

$$(1, 2, \dots, k).$$

Portanto, $(1, 2, \dots, k)$ é uma cobertura de T , como queríamos demonstrar. $\square$

Capítulo 7

Retorno ao Discreto e Resultado Assintótico

Neste capítulo concluímos a passagem do modelo contínuo de árvores métricas para o cenário discreto de grafos finitos, obtendo o resultado principal do [NORIN e TURCOTTE, 2024](#). A ideia é combinar o Teorema 6.2.1, demonstrado no capítulo anterior para árvores métricas, com um lema simples que transfere coberturas de uma árvore métrica T^M para a árvore discreta subjacente T , acrescentando 1 a todos os raios.

O resultado final é o Teorema 7.1.1, que afirma que o número de queima satisfaz $b(G) \leq (1 + o(1))\sqrt{n}$ para todo grafo conexo G com n vértices. Em termos da Conjectura do Número de Queima, isso mostra que a conjectura vale assintoticamente: o limite $\sqrt{n}$ é, de fato, a ordem de grandeza correta do número de queima.

7.1 Enunciado do resultado principal

Recordamos primeiro que, se T é uma árvore geradora de um grafo conexo G , então qualquer estratégia de queima que funcione em T também funciona em G . Em particular,

$$b(G) \leq b(T),$$

pois adicionar arestas aos caminhos de propagação do fogo não pode dificultar a cobertura do grafo. Assim, para demonstrar um limite superior assintótico para $b(G)$ em função de $n = |V(G)|$, é suficiente trabalhar com árvores.

O resultado principal de Norin e Turcotte [NORIN e TURCOTTE, 2024](#), que enuncia a forma assintótica da Conjectura do Número de Queima, é o seguinte.

Teorema 7.1.1 (Teorema 1.2, Norin–Turcotte). *Se G é um grafo conexo com n vértices, então*

$$b(G) \leq (1 + o(1))\sqrt{n}.$$

Equivalentemente, para cada $\varepsilon > 0$ existe um inteiro N tal que, se G é um grafo conexo

com $n \geq N$ vértices, então

$$b(G) \leq (1 + \varepsilon)\sqrt{n}.$$

É exatamente essa formulação quantificada que utilizaremos na demonstração.

7.2 Transferência métrica–discreta

Nesta seção registramos o lema que faz a ponte entre o modelo contínuo e o modelo discreto. Toda a construção de árvores métricas, bolas $B_{T^M}(x, r)$ e coberturas $(r_1, \dots, r_m) \in C(T^M)$ já foi introduzida anteriormente; aqui apenas utilizamos essa estrutura.

Dada uma árvore discreta T , denotamos por T^M a árvore métrica correspondente, obtida substituindo cada aresta por um intervalo de comprimento 1. Notamos que, por construção, as distâncias entre vértices são preservadas:

$$d_{T^M}(u, v) = d_T(u, v) \quad \text{para todo } u, v \in V(T).$$

O lema seguinte (Lema 5.4 em [NORIN e TURCOTTE, 2024](#)) formaliza o fato intuitivo de que, se conseguimos cobrir T^M com bolas contínuas de raios r_i , então podemos cobrir T com bolas centradas em vértices, aumentando uniformemente todos os raios em 1.

Lema 7.2.1 (Lema 5.4, Norin–Turcotte). *Se T é uma árvore discreta e $(r_1, \dots, r_m)$ é uma cobertura da árvore métrica correspondente T^M , então $(r_1 + 1, \dots, r_m + 1)$ é uma cobertura de T .*

Demonstração. Seja $v_1, \dots, v_m \in T^M$ tal que

$$T^M = \bigcup_{i=1}^m B_{T^M}(v_i, r_i).$$

Para cada $i \in \{1, \dots, m\}$, seja $u_i \in V(T)$ uma extremidade da aresta (segmento) de T^M que contém v_i . Em particular, $d_{T^M}(u_i, v_i) \leq 1$, pois u_i está a distância no máximo 1 de qualquer ponto no interior da aresta.

Se $y \in B_{T^M}(v_i, r_i)$, então

$$d_{T^M}(u_i, y) \leq d_{T^M}(u_i, v_i) + d_{T^M}(v_i, y) \leq 1 + r_i,$$

o que implica

$$B_{T^M}(v_i, r_i) \subseteq B_{T^M}(u_i, r_i + 1).$$

Logo,

$$T^M = \bigcup_{i=1}^m B_{T^M}(v_i, r_i) \subseteq \bigcup_{i=1}^m B_{T^M}(u_i, r_i + 1).$$

Como $V(T) \subseteq T^M$ e, para vértices, as distâncias em T e em T^M coincidem, temos

$$V(T) \subseteq \bigcup_{i=1}^m B_{T^M}(u_i, r_i + 1) \cap V(T) = \bigcup_{i=1}^m B_T(u_i, r_i + 1).$$

Isto é, T é coberta pelas bolas discretas $B_T(u_i, r_i + 1)$, e portanto $(r_1 + 1, \dots, r_m + 1)$ é uma cobertura de T , como queríamos demonstrar. $\square$

O Lema 7.2.1 será aplicado diretamente ao final da prova do Teorema 7.1.1: primeiro construiremos uma cobertura de T^M com raios inteiros $(1, \dots, k)$, usando o Teorema 6.2.1; em seguida, aplicaremos o lema para obter uma cobertura de T com raios $(2, \dots, k + 1)$, que será então relacionada ao número de queima.

7.3 Demonstração do Teorema 1.2

Estamos prontos para demonstrar o Teorema 7.1.1. A prova é curta, mas condensa todo o trabalho analítico e probabilístico desenvolvido nos capítulos anteriores. Usaremos explicitamente o Teorema 6.2.1 e o Lema 7.2.1.

Demonstração do Teorema 7.1.1. Seja $0 < \varepsilon < 1$. Queremos mostrar que existe $N \in \mathbb{N}$ tal que, se G é um grafo conexo com $n \geq N$ vértices, então

$$b(G) \leq (1 + \varepsilon)\sqrt{n}.$$

Definimos

$$\varepsilon' := \varepsilon^2.$$

Aplicaremos o Teorema 6.2.1 com o parâmetro ε' em lugar de ε . Denotamos por $K_{5,3}(\varepsilon')$ a constante fornecida por aquele teorema. Seja

$$N := \max \left\{ \left(K_{5,3}(\varepsilon') \right)^2, \frac{6}{\varepsilon} \right\}.$$

Mostraremos que esse N satisfaz a propriedade desejada.

Seja então G um grafo conexo com $n \geq N$ vértices. Como observado acima, é suficiente considerar uma árvore geradora T de G : qualquer sequência de raios que queima T também queima G , de modo que

$$b(G) \leq b(T).$$

Denotamos por T^M a árvore métrica associada a T , construída anteriormente. O comprimento total de T^M é

$$|T^M| = |E(T)| = n - 1.$$

Definimos agora

$$k := \left\lceil \sqrt{\frac{n}{1 - \varepsilon'}} \right\rceil.$$

Temos

$$k \geq \sqrt{\frac{n}{1-\varepsilon'}} \geq \sqrt{\frac{N}{1-\varepsilon'}} \geq \sqrt{\frac{(K_{5.3}(\varepsilon'))^2}{1-\varepsilon'}} \geq K_{5.3}(\varepsilon'),$$

pois $1 - \varepsilon' < 1$. Além disso,

$$|T^M| = n - 1 \leq n \leq (1 - \varepsilon') \cdot \left(\left\lceil \sqrt{\frac{n}{1-\varepsilon'}} \right\rceil \right)^2 = (1 - \varepsilon')k^2,$$

onde usamos o fato de que $k^2 \geq \frac{n}{1-\varepsilon'}$. Assim, T^M satisfaz as hipóteses do Teorema 6.2.1 com parâmetro ε' : temos

$$k \geq K_{5.3}(\varepsilon') \quad \text{e} \quad |T^M| \leq (1 - \varepsilon')k^2.$$

Portanto, pelo Teorema 6.2.1, a sequência de raios inteiros

$$(1, 2, \dots, k)$$

é uma cobertura de T^M .

Aplicamos agora o Lema 7.2.1. Como $(1, \dots, k)$ é uma cobertura de T^M , segue do lema que

$$(2, 3, \dots, k + 1)$$

é uma cobertura de T . Em particular, existe uma estratégia de queima de T com k ignições, cujos raios (isto é, os tempos de propagação do fogo em torno de cada ignição) são $2, 3, \dots, k + 1$.

O número de queima $b(T)$ é o menor inteiro ℓ para o qual existe alguma sequência de raios $(r_1, \dots, r_\ell)$ que cobre T . A existência de uma cobertura com raios $(2, \dots, k + 1)$ implica a cota simples

$$b(T) \leq (k + 1) + 1,$$

onde o $+1$ final corresponde à possibilidade de uma ignição inicial de raio zero (inútil para a cobertura métrica, mas compatível com a dinâmica de queima discreta). Assim,

$$b(T) \leq \left\lceil \sqrt{\frac{n}{1-\varepsilon'}} \right\rceil + 2.$$

Usamos agora estimativas elementares para comparar esse valor com $(1 + \varepsilon)\sqrt{n}$. Primeiro, pela desigualdade $\lceil x \rceil \leq x + 1$ para $x \in \mathbb{R}$, obtemos

$$b(T) \leq \sqrt{\frac{n}{1-\varepsilon'}} + 3.$$

Como $\varepsilon' = \varepsilon^2$ e $0 < \varepsilon < 1$, há uma constante universal (cuja forma exata não é importante aqui) tal que

$$\sqrt{\frac{1}{1-\varepsilon^2}} \leq 1 + \frac{\varepsilon}{2},$$

para todo ε pequeno. Em particular,

$$\sqrt{\frac{n}{1-\varepsilon'}} \leq \left(1 + \frac{\varepsilon}{2}\right) \sqrt{n}.$$

Por outro lado, como $n \geq N \geq \frac{6}{\varepsilon}$, temos

$$\frac{3}{\sqrt{n}} \leq \frac{3}{\sqrt{6/\varepsilon}} = \sqrt{\frac{9\varepsilon}{6}} \leq \frac{\varepsilon}{2},$$

para $0 < \varepsilon \leq 1$, de modo que

$$3 \leq \frac{\varepsilon}{2} \sqrt{n}.$$

Combinando as duas desigualdades, obtemos

$$b(T) \leq \left(1 + \frac{\varepsilon}{2}\right) \sqrt{n} + 3 \leq \left(1 + \frac{\varepsilon}{2}\right) \sqrt{n} + \frac{\varepsilon}{2} \sqrt{n} = (1 + \varepsilon) \sqrt{n}.$$

Finalmente, como $b(G) \leq b(T)$, concluimos que

$$b(G) \leq (1 + \varepsilon) \sqrt{n},$$

para todo grafo conexo G com $n \geq N$ vértices. Como $\varepsilon > 0$ foi arbitrário, isso é equivalente a dizer que $b(G) \leq (1 + o(1)) \sqrt{n}$, o que demonstra o Teorema 7.1.1. $\square$

7.4 Comentários finais

O argumento deste capítulo encapsula, em poucas linhas, todo o conteúdo analítico e probabilístico desenvolvido anteriormente. O Teorema 6.2.1 fornece, no modelo de árvores métricas, uma cobertura por raios inteiros $(1, \dots, k)$ sempre que o comprimento total da árvore é estritamente menor que $(1 - \varepsilon)k^2$. O Lema 7.2.1 mostra que, a partir de tal cobertura contínua, basta aumentar uniformemente os raios em 1 para obter uma cobertura da árvore discreta subjacente.

Ao ajustar cuidadosamente os parâmetros ε' e N , esse procedimento se traduz em uma cota assintótica para o número de queima de qualquer grafo conexo, com erro multiplicativo arbitrariamente pequeno. Dessa forma, o Teorema 7.1.1 fecha o ciclo iniciado na reinterpretação métrica do problema: começamos traduzindo a dinâmica de queima em termos de coberturas por bolas em árvores métricas, passamos por uma etapa fracionária e probabilística via medida de expectativa e controle de momento, e terminamos retornando ao cenário discreto com uma afirmação precisa sobre $b(G)$ em função de n .

Capítulo 8

Conclusão

Nesta dissertação estudamos o número de queima a partir de uma perspectiva de cobertura, com o objetivo de apresentar de forma didática as ideias que levam ao resultado assintótico mais forte conhecido para grafos gerais. A motivação central foi compreender como o processo discreto de queima pode ser reinterpretado como um problema geométrico em árvores e, a partir daí, como ferramentas probabilísticas relativamente simples permitem “regularizar” coberturas determinísticas em estruturas contínuas. O fio condutor foi, portanto, transformar um processo dinâmico em um problema de decomposição e cobertura, reduzir a análise a árvores, passar ao análogo métrico e, finalmente, controlar quantitativamente coberturas aleatórias por meio de uma linguagem de medidas.

O primeiro ganho conceitual do ponto de vista de cobertura é que sequências de ignição podem ser vistas como escolhas sucessivas de bolas cujos raios crescem de maneira prescrita. Nessa leitura, a dificuldade combinatória do processo fica concentrada em como posicionar centros que maximizem a região coberta com um orçamento de raios fixado. A redução a árvores, por sua vez, fornece um ambiente onde distâncias têm uma estrutura particularmente rígida e onde decomposições locais podem ser globalizadas com perda controlada. Essa passagem é decisiva porque permite substituir um grafo arbitrário por uma árvore geradora sem piorar o problema de queima, e depois substituir a árvore discreta por sua versão métrica, onde argumentos geométricos e de “custo versus tamanho” tornam-se mais transparentes.

Na parte determinística, desenvolvemos a base que sustenta todo o argumento probabilístico posterior: lemas que exibem coberturas eficientes em árvores métricas e que introduzem, de modo operacional, as noções de frugalidade e flexibilidade. O ponto essencial é que certos casos-base admitem famílias contínuas de coberturas com custo quase fixo e com liberdade suficiente para parametrizações uniformes; isso prepara o terreno para a aleatorização, pois as parametrizações contínuas são justamente o mecanismo que gera distribuições quase uniformes de raios ao longo de um intervalo.

O núcleo técnico-probabilístico do trabalho aparece quando, em vez de fixar uma cobertura, passamos a estudar distribuições de probabilidade sobre o espaço de coberturas e a sua medida de expectativa. Essa expectativa codifica, em média, quantos raios caem em cada subintervalo de comprimentos, e o momento associado se interpreta como duas

vezes o custo médio (isto é, a soma esperada dos raios) de uma cobertura aleatória. A partir daí, o objetivo deixa de ser construir uma cobertura específica e passa a ser construir uma distribuição cujo perfil médio de raios seja quase uniforme e cujo custo esperado permaneça controlado. A noção de medidas (r, δ) -controladas formaliza exatamente esse compromisso: ela impõe uma decomposição “em caudas uniformes” e torna possível um esquema indutivo no qual distribuições controladas em componentes menores são coladas para produzir distribuições controladas no todo.

Com essa linguagem estabelecida, o resultado-chave é o teorema métrico (NORIN e TURCOTTE, 2024) que garante a existência de uma medida de probabilidade ν em $C(T, r)$ tal que a expectativa E_ν é dominada por uma constante $(1 + \varepsilon)$ vezes a medida uniforme em $[0, r]$, desde que T seja suficientemente grande em comparação com r . Em termos informais, isso significa que existe uma forma de escolher coberturas aleatórias que “usa” raios em $[0, r]$ de modo aproximadamente equilibrado, sem inflar demais o custo médio. Essa etapa concentra o conteúdo analítico e probabilístico do método e explica por que o parâmetro ε aparece naturalmente: ele quantifica a folga com que aceitamos dominar a uniformidade ideal e, ao mesmo tempo, impõe uma condição de separação de escalas entre $|T|$ e r .

Por fim, ao combinar essa construção métrica com o procedimento de retorno ao caso discreto, obtemos a cota assintótica para grafos conexos. Na forma em que aparece no final do texto, mostramos que, para todo $\varepsilon > 0$, existe N tal que todo grafo conexo G com $n \geq N$ vértices satisfaz $b(G) \leq (1 + \varepsilon)\sqrt{n}$, e portanto $b(G) \leq (1 + o(1))\sqrt{n}$. Como destacado no encerramento do capítulo final, esse argumento sintetiza em poucas linhas toda a infraestrutura construída ao longo do trabalho: reduções estruturais, coberturas determinísticas em árvores métricas, aleatorização via medida de expectativa e controle do custo via momento, culminando no passo final que reconecta o contínuo ao discreto.

Do ponto de vista de trabalhos futuros, a direção mais imediata consiste em compreender com mais precisão como o parâmetro ε se propaga ao longo de toda a cadeia de implicações. No método de Norin & Turcotte, ε governa hipóteses de escala (como exigências do tipo $|T| \geq c \varepsilon^{-1} r$ no resultado métrico) e também influencia escolhas intermediárias (por exemplo, substituições do tipo $\varepsilon' = \varepsilon/2$ e a forma como perdas de fator se acumulam em passos de colagem e de arredondamento). Tornar explícitas essas dependências tem duas consequências naturais. A primeira é obter limites efetivos para $N(\varepsilon)$, isto é, quantificar quão grande n precisa ser para garantir $b(G) \leq (1 + \varepsilon)\sqrt{n}$ com constantes rastreadas e comparáveis. A segunda é investigar se o esquema pode ser refinado para reduzir a folga introduzida em cada etapa, seja diminuindo constantes universais na condição de separação de escalas, seja reorganizando a indução para minimizar a degradação de ε na passagem entre níveis de escala.

Uma segunda linha natural, conectada à anterior, é buscar taxas explícitas para o termo $o(1)$ quando se escreve $b(G) \leq (1 + o(1))\sqrt{n}$. Isso exige reescrever partes do argumento com controle quantitativo fino, substituindo estimativas de existência por desigualdades com parâmetros acompanhados até o final. Em um contexto aplicado, essa informação é relevante porque separa um resultado puramente assintótico de uma cota utilizável em regimes moderados de n . Por fim, permanecem abertas direções mais combinatórias, como entender em que medida a abordagem de cobertura pode ser adaptada a classes específicas de grafos onde se espera rigidez adicional (por exemplo, restrições de diâmetro,

arboricidade ou estrutura de menores), ou ainda como o ponto de vista probabilístico em árvores métricas pode inspirar algoritmos aproximativos para construir sequências de ignição curtas em instâncias concretas.

Em síntese, este trabalho procurou tornar transparente a ideia de que o problema do número de queima é, em essência, um problema de cobertura com restrições geométricas, e que a principal inovação do resultado assintótico moderno está em introduzir uma noção de uniformidade média para coberturas aleatórias, mensurada por uma medida de expectativa e controlada por um funcional de momento. Ao explicitar essa ponte entre o discreto e o contínuo, bem como os mecanismos de colagem e de indução em escala que sustentam o argumento, esperamos ter produzido uma apresentação que não apenas reproduz o resultado final, mas também esclarece por que o método funciona e quais são os pontos em que novas melhorias podem surgir.

Referências

- [ALON e SPENCER 2016] Noga ALON e Joel H. SPENCER. *The Probabilistic Method*. 4ª ed. Wiley, 2016 (citado na pg. 45).
- [BALOGH *et al.* 2012] József BALOGH, Béla BOLLOBÁS e Robert MORRIS. “Graph bootstrap percolation”. *Random Structures & Algorithms* 41.4 (2012), pp. 413–440 (citado na pg. 1).
- [BASTIDE *et al.* 2021] Paul BASTIDE, Jérémie CHALOPIN, Damián GONÇALVES, Pascal OCHEM e Alain PINLOU. “Closer to the burning number conjecture”. *arXiv preprint arXiv:2110.10530* (2021) (citado na pg. 3).
- [BESSY *et al.* 2017] Stéphan BESSY, Anthony BONATO, Jeannette JANSSEN, Dieter RAUTENBACH e Elham ROSHANBIN. “Burning a graph is hard”. *Discrete Applied Mathematics* 232 (2017), pp. 73–82 (citado na pg. 2).
- [BONATO *et al.* 2016] Anthony BONATO, Jeannette JANSSEN e Elham ROSHANBIN. “How to burn a graph”. *Internet Mathematics* 12.1-2 (2016), pp. 85–100 (citado nas pgs. 1–3, 5).
- [FINBOW e MACGILLIVRAY 2009] Stephen FINBOW e Gary MACGILLIVRAY. “The firefighter problem: a survey of results, directions and questions”. *Australasian Journal of Combinatorics* 43 (2009), pp. 57–77 (citado na pg. 1).
- [HOEFFDING 1963] Wassily HOEFFDING. “Probability inequalities for sums of bounded random variables”. *Journal of the American Statistical Association* 58.301 (1963), pp. 13–30 (citado na pg. 46).
- [LAND e LU 2016] Max LAND e Linyuan LU. “An upper bound on the burning number of graphs”. *arXiv preprint arXiv:1606.07614* (2016) (citado na pg. 3).
- [MURAKAMI 2024] Yukihiro MURAKAMI. “The burning number conjecture is true for trees without degree-2 vertices”. *Graphs and Combinatorics* 40.4 (2024), p. 82 (citado na pg. 3).
- [NORIN e TURCOTTE 2024] Sergey NORIN e Jérémie TURCOTTE. “The burning number conjecture holds asymptotically”. *Journal of Combinatorial Theory, Series B* 168 (2024), pp. 208–235 (citado nas pgs. 3, 5, 7, 12–16, 26, 35, 46, 47, 55, 56, 62).